UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE CIÊNCIAS

DEPARTAMENTO DE ESTATÍSTICA E MATEMÁTICA APLICADA

PROGRAMA DE PÓS-GRADUAÇÃO EM MODELAGEM E MÉTODOS QUANTITATIVOS

MESTRADO ACADÊMICO EM MODELAGEM E MÉTODOS QUANTITATIVOS

ICARO DE SOUSA RODRIGUES

USO DE MODELOS DE APRENDIZAGEM DE MÁQUINA PARA OTIMIZAÇÃO DE SIMULADORES DE POÇOS DE PETRÓLEO MARÍTIMO

FORTALEZA

2026

ICARO DE SOUSA RODRIGUES

USO DE MODELOS DE APRENDIZAGEM DE MÁQUINA PARA OTIMIZAÇÃO DE SIMULADORES DE POÇOS DE PETRÓLEO MARÍTIMO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Modelagem e Métodos Quantitativos do Programa de Pós-Graduação em Modelagem e Métodos Quantitativos do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Engenharia Xxxxxx. Área de Concentração: Ciência de Dados

Orientador: Prof. Dr. Jesus Ossian da Cunha Silva

FORTALEZA

2026

ICARO DE SOUSA RODRIGUES

USO DE MODELOS DE APRENDIZAGEM DE MÁQUINA PARA OTIMIZAÇÃO DE SIMULADORES DE POÇOS DE PETRÓLEO MARÍTIMO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Modelagem e Métodos Quantitativos do Programa de Pós-Graduação em Modelagem e Métodos Quantitativos do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Engenharia Xxxxxx. Área de Concentração: Ciência de Dados

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Jesus Ossian da Cunha Silva (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Michael Ferreira de Souza
Universidade Federal do Ceará (UFC)

Prof. Dr. Luís Fabrício de Freitas Souza
Universidade Federal do Cariri (UFCA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

Ao Prof. Dr. Ricardo Silva Thé Pontes por me orientar em minha tese de doutorado.

Ao Prof. Dr. Tobias Rafael Fernandes Neto, coordenador do Laboratório de Sistemas Motrizes (LAMOTRIZ) onde este *template* foi desenvolvido.

Ao Doutorando em Engenharia Elétrica, Ednardo Moreira Rodrigues, e seu assistente, Alan Batista de Oliveira, aluno de graduação em Engenharia Elétrica, pela adequação do *template* utilizado neste trabalho para que o mesmo ficasse de acordo com as normas da biblioteca da Universidade Federal do Ceará (UFC).

Aos bibliotecários da Universidade Federal do Ceará: Francisco Edvander Pires Santos, Juliana Soares Lima, Izabel Lima dos Santos, Kalline Yasmin Soares Feitosa e Eliene Maria Vieira de Moura, pela revisão e discussão da formatação utilizada neste *template*.

Ao aluno Thiago Nascimento do curso de ciência da computação da Universidade Estadual do Ceará que elaborou o *template* do qual este trabalho foi adaptado para Universidade Federal do Ceará.

Ao Prof. Dr. Humberto de Andrade Carmona do Curso de Física da UFC pelo primeiro incentivo para o uso do LaTeX.

Ao aluno de graduação em engenharia elétrica e amigo, Lohan Costa por me apresentar a plataforma *ShareLatex* que depois migrou para a plataforma *OverLeaf*.

Aos amigos de laboratório, Felipe Bandeira, Renan Barroso e Roney Coelho, pelas discussões sobre os recursos do LaTeX.

Aos meus pais, irmãos e sobrinhos, que nos momentos de minha ausência dedicados ao estudo superior, sempre fizeram entender que o futuro é feito a partir da constante dedicação no presente!

Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender.

E à Fundação Cearense de Apoio ao Desenvolvimento (Funcap), na pessoa do Presidente Tarcísio Haroldo Cavalcante Pequeno pelo financiamento da pesquisa de doutorado via bolsa de estudos.

"O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado."

(Ariano Suassuna)

RESUMO

Esta dissertação de mestrado apresenta a aplicação de modelos de Aprendizagem de Máquina para a otimização de simuladores de poços de petróleo marítimo. Tais modelos utilizam-se de dados e, por meio de treinamentos específicos, tornam-se capazes de mimetizar o comportamento de simuladores físicos com precisão aceitável e baixo custo computacional. A metodologia abrange a extração de dados reais do sistema de Consulta de Dados Públicos (CDP) da Petrobras, referente ao período de janeiro de 2018 a dezembro de 2025. O fluxo de trabalho incluiu um processo de escolha dos dados a serem expostos aos modelos, sendo selecionados especificamente dados de poços situados no Rio de Janeiro, na Bacia de Campos, a fim de se manter dados de poços fisicamente próximos, seguido então da limpeza de dados (*Data Cleansing*), engenharia de atributos, segmentação dos dados, treinamento e avaliação dos modelos. Foram realizados experimentos computacionais comparando 8 (oito) algoritmos de Aprendizagem de Máquina, que tinham como variável alvo a produção diária dos poços, submetidos à otimização de hiperparâmetros via *GridSearchCV*. Os resultados demonstram que o modelo baseado em *Gradient Boosting* obteve o melhor desempenho, alcançando um coeficiente de determinação (R^2) de 0,8235 e obtendo uma raiz de erro quadrático médio (RMSE) igual a 783,7745, o que representa 31.58% da média de produção diária dos poços. Conclui-se que a abordagem não linear é essencial para capturar as complexas interações do reservatório, validando o uso de modelos *surrogate* como ferramentas eficientes para o gerenciamento de produção *offshore*.

Palavras-chave: Aprendizagem de Máquina. Modelos Surrogate. Otimização. Poços de Petróleo.

ABSTRACT

This Master's qualification proposal presents the application of Machine Learning models for the optimization of offshore oil well simulators. These data-driven models, through specific training, are capable of mimicking the behavior of physical simulators with acceptable precision and low computational cost. The methodology covers the extraction of real-world data from Petrobras' Public Data Consultation (CDP) system, spanning from January 2023 to August 2025. The workflow included a rigorous data cleansing process, feature engineering, and mathematical transformations for variance stabilization. Computational experiments were conducted comparing 8 (eight) Machine Learning algorithms, subjected to hyperparameter optimization via *GridSearchCV*. Results demonstrate that the *Random Forest Regressor*-based model achieved the best performance, reaching a coefficient of determination (R^2) of 0.9272 and reducing the root mean squared error (RMSE) by more than 58% compared to linear models. As subsequent steps leading up to the thesis defense, it is intended to study and implement Deep Learning and Physics-Informed Neural Networks (PINN) models, as well as integrate the final predictive model with the `gurobipy` optimization library to obtain optimized operational setpoints. It is concluded that the non-linear approach is essential for capturing complex reservoir interactions, validating the use of surrogate models as efficient tools for offshore production management.

Keywords: Machine Learning. Surrogate Models. Optimization. Oil Wells.

LISTA DE FIGURAS

Figura 1 – *Blowout Preventer*/Dispositivo antirruptura (BOP) 15
Figura 2 – Árvore de Natal Molhada 15

LISTA DE TABELAS

Tabela 1 – Métricas Consolidadas de Desempenho dos Modelos 47
Tabela 2 – Parâmetros do Problema 50
Tabela 3 – Limites das Variáveis 51
Tabela 4 – Soluções das Variáveis 51

LISTA DE SÍMBOLOS

bbl/dia	Barril por dia

SUMÁRIO

1 INTRODUÇÃO 14
2 PROBLEMA 18
2.1 Formulação do Problema 18
2.2 Problema Linear 20
2.3 Problema Não Linear 21
2.3.1 Modelos baseados em Instâncias e Vizinhança 21
2.3.2 Algoritmos baseados em Support Vector Machines/Máquinas de Vetores de Suporte (SVM) 23
2.3.3 Algoritmos baseados em Árvores de Decisão 27
2.3.3.1 Random Forest *27*
2.3.3.2 Gradient Boosting *29*
2.4 Métricas 32
3 FUNDAMENTAÇÃO TEÓRICA 34
3.1 Fundamentos de Pesquisa Operacional (PO) 34
3.2 Fundamentos de Limpeza de Dados para Modelagem 35
3.3 Fundamentos de *Machine Learning*/Aprendizagem de Máquina (*ML*) . . 36
3.3.1 Generalização e Overfitting 37
3.4 Modelos *Surrogate* na Otimização de Sistemas de Produção 37
3.5 Formalização Matemática dos Modelos de Aprendizado de Máquina . . 38
3.5.1 Regressores Lineares e Regularização 38
3.5.2 Modelos de Vizinhança e Suporte (KNN e SVR) 39
3.5.3 Modelos Baseados em Árvores e Ensembles (Random Forest e XGBoost) . 39
4 PROPOSTA E METODOLOGIA 40
5 EXPERIMENTOS COMPUTACIONAIS 47
5.1 Métricas Consolidadas de Desempenho 47
5.2 Análise e Discussão dos Resultados 47
5.2.1 Performance dos Modelos Lineares (Base) 48
5.2.2 O Salto de Precisão dos Modelos Não-Lineares 48
5.2.3 Análise do Trade-Off: Precisão, Generalização e Tempo 48
5.3 Definição do Modelo Final 49

5.4 **Testes com o Gurobi** 50
6 **CONCLUSÃO** 52
REFERÊNCIAS 53

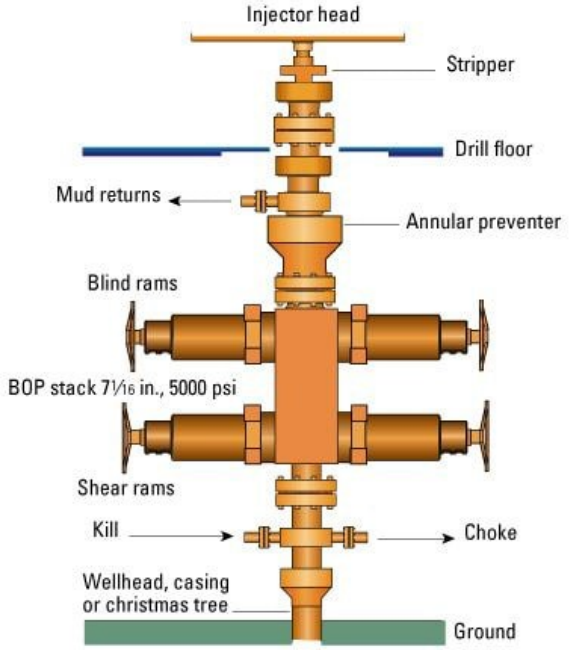
1 INTRODUÇÃO

A extração de petróleo em ambiente marítimo constitui uma das atividades de engenharia de maior complexidade operacional e volume de investimento de capital (CHAKRABARTI *et al.*, 2005), mantendo papel estratégico na segurança e no suprimento da matriz energética mundial (IEA, 2025). Os esforços em Pesquisa e Desenvolvimento (P&D) envolvidos nessas operações são cruciais para superar os desafios tecnológicos, especialmente em águas profundas (MORAIS, 2011). Esse processo, que se inicia com campanhas exploratórias e culmina na produção efetiva, é realizado a partir de estruturas especializadas, as plataformas de petróleo, e exige um rigoroso licenciamento ambiental em todas as suas fases, dada a necessidade de compreender e mitigar os impactos ambientais gerados pela atividade (MARTINS *et al.*, 2015).

De acordo com (MME, 2023), a etapa de desenvolvimento do campo de petróleo e gás natural envolve a perfuração de poços e a instalação de um complexo sistema submarino, havendo diversas técnicas para a construção e montagem de uma plataforma, sendo um dos fatores determinantes a profundidade do campo de petróleo e gás. Em profundidades de até 400 metros, o tipo de plataforma é considerada de águas rasas, e sua estrutura pode ficar sobre torres de concreto e aço, capazes de aguentar todas as intempéries do tempo e mar revolto. Já no caso de uma maior profundidade, fazendo com que a plataforma esteja parcialmente submersa, as plataformas são do tipo semissubmersíveis, tendo uma maior estabilidade, visto que esse são instalados pontos de ancoragem para evitar que as instalações fiquem à deriva no oceano. Por fim, existe a chamada *Floating Production Storage and Offloading*/Unidade Flutuante de Armazenamento e Transferência (*FPSO*), que são navios com capacidade de processar, armazenar e transferir petróleo e gás natural a outros navios.

Com a perfuração do poço, feita por meio do uso de uma broca com dente de aço, é necessária a instalação do equipamento de segurança chamado BOP, que pode ser visto na imagem 2. Esse dispositivo consiste em um sistema hidráulico ou eletro-hidráulico fundamental para vedar o poço e prevenir acidentes de vazamento sob alta pressão. Para conectar o BOP na cabeça do poço à unidade de perfuração na superfície, utiliza-se do *drilling riser*, que é uma coluna tubular essencial que atua como um conduto de retorno dos fluidos de perfuração e guia para as ferramentas. Há também a chamada Árvore de Natal Molhada, que pode ser vista na Figura **??**, um conjunto de válvulas que gerencia o fluxo de produção. A operação de instalação desses equipamentos críticos, como o lançamento e descida dos *risers* e o assentamento do BOP no solo marítimo, representa um dos maiores desafios logísticos e de segurança em sistemas de

Figura 1



Blowout preventer. This BOP configuration is typical for a well drilled with a hole size greater than 4-in. diameter.

Figura 1 – BOP



Figura 2 – Árvore de Natal Molhada

perfuração marítima (TSUKADA *et al.*, 2007). O produto final (petróleo e gás) é escoado por dutos ou navios petroleiros.

Quanto à simulação numérica de reservatórios, este é um método amplamente reconhecido e eficaz para a exploração de questões complexas e o estudo do comportamento de fluxo em condições reais de reservatório (SIKANYIKA *et al.*, 2023). Devido ao alto custo e aos desafios operacionais, especialmente em campos *offshore* e reservatórios de baixa permeabilidade, a indústria busca sempre melhorar a produção, com menos poços, tornando a precisão e a eficiência da modelagem críticas (WU *et al.*, 2025).

A modelagem de reservatórios é governada por equações diferenciais parciais que descrevem o fluxo de fluidos (óleo, gás, água) em meios porosos, como as equações do modelo *Black-Oil* (SIKANYIKA *et al.*, 2023). Além da complexidade do reservatório, a simulação detalhada de componentes do poço também exige a solução de equações de alta complexidade. Por exemplo, a otimização de dispositivos de controle de fluxo requer a aplicação de *Computational Fluid Dynamics*/Dinâmica dos Fluidos Computacional (CFD) para resolver as equações de continuidade e de momento para escoamento turbulento, muitas vezes empregando modelos como o $k-\varepsilon$ (GAO *et al.*, 2023).

O tempo de processamento demandado pelos modelos de alta fidelidade — que pode alcançar horas ou dias para a simulação de um único cenário em campos complexos — configura uma importante oportunidade de ganho de eficiência computacional. A redução desse tempo de resposta potencializa a execução e amplia o alcance de tarefas de gerenciamento e otimização que dependem de múltiplas avaliações sucessivas, tais como:

- ***Uncertainty Quantification*/Quantificação de Incerteza (UQ)**: A avaliação robusta da incerteza dos parâmetros do reservatório (porosidade, permeabilidade, etc.) exige a execução de milhares de simulações (e.g., Monte Carlo) (WU *et al.*, 2025).
- **Otimização de Produção e Otimização Econômica**: A busca pelo posicionamento ideal de poços ou pela maximização do Valor Presente Líquido (VPL) envolve a iteração contínua sobre diversos parâmetros (espaçamento, fraturamento, padrões de injeção), sendo impulsionada pelo uso de modelos ágeis para avaliar cada tentativa (WU *et al.*, 2025).
- **Estudo de Cenários**: A comparação entre diferentes estratégias, como poços horizontais versus verticais com injeção de água, pode ser substancialmente expandida ao se viabilizar um maior número de iterações em busca de maior eficiência de recuperação (SIKANYIKA *et al.*, 2023).

Diante desse panorama, a literatura recente tem explorado amplamente a interseção entre computação de alto desempenho e técnicas de Inteligência Artificial (IA) para contornar tais restrições temporais. Conforme destacado por Portella *et al.* (2022), a simulação de fluxo em reservatórios e a imagiologia sísmica constituem as cargas de trabalho mais intensivas em supercomputadores no setor de óleo e gás, motivando o desenvolvimento de estratégias inteligentes que acelerem o tempo de resposta sem comprometer o rigor dos resultados. Enquanto abordagens como o *TunaOil* atuam na sintonização de parâmetros internos do próprio simulador

numérico para otimizar o tempo de CPU, uma vertente complementar e altamente promissora consiste no emprego de modelos substitutos. Por meio dessa abordagem, algoritmos de *ML* são treinados a partir de históricos e execuções prévias para emular o comportamento das variáveis de interesse com baixo custo computacional, permitindo que rotinas complexas de otimização matemática explorem amplamente o espaço de busca e acelerem a tomada de decisão estratégica no desenvolvimento do campo.

A estrutura deste trabalho está organizada em capítulos que detalham o problema abordado, o embasamento teórico, os métodos utilizados nos experimentos e resultados obtidos. A organização segue a seguinte ordem:

- **Capítulo 2:** Define formalmente o problema de previsão de vazão, estabelecendo as modelagens matemáticas para as abordagens linear e não linear, além de descrever as métricas estatísticas utilizadas para a otimização dos modelos.
- **Capítulo 3:** Reúne a fundamentação teórica necessária para a compreensão dos conceitos de extração de petróleo *offshore*, modelagem *surrogate* e os princípios matemáticos dos algoritmos de Aprendizado de Máquina selecionados.
- **Capítulo 4:** Detalha o fluxo metodológico, abrangendo a extração de dados no sistema de Consulta de Dados Públicos (CDP), o processo rigoroso de limpeza de dados (*Data Cleansing*), a engenharia de atributos e a configuração dos experimentos computacionais.
- **Capítulo 5:** Expõe os resultados alcançados, apresentando a comparação de desempenho entre os modelos lineares, de conjunto e redes neurais, baseando-se nas métricas de erro estatístico e custo computacional.
- **Capítulo 6:** Sintetiza as principais conclusões obtidas, discute as limitações da pesquisa e propõe sugestões de trabalhos futuros para o aprimoramento da modelagem preditiva em sistemas de produção.

2 PROBLEMA

A otimização da produção de petróleo em poços é uma tarefa crítica de engenharia, cuja eficiência está diretamente ligada à acurácia da previsão da Vazão Diária de Petróleo ($\hat{y}$) em função das variáveis operacionais e de reservatório (X). As complexas interações entre estas variáveis frequentemente dificultam a obtenção de estimativas precisas por métodos tradicionais, que falham em mapear a função $f(X)$ de forma satisfatória. Tais iterações entre as variáveis, pode classificar o problema quanto à sua linearidade, se este será **linear** ou **não-linear**, e dada a grande quantidade de variáveis, é muito difícil classificar o problema apenas com a observação dos dados. Sendo assim, o problema abordado será modelado de ambas as formas e serão utilizadas as métricas dos modelos de *ML*, apresentados no Capítulo 5, para determinar a natureza do problema, levando em consideração que foram utilizados modelos diferentes, onde alguns assumem o problema como linear e outros como não-linear, o que será melhor detalhado no Capítulo 4.

Abaixo será apresentada a formulação matemática do problema, bem como os 2 tipos de modelagem do problema de acordo com as naturezas dos algoritmos, e por fim do problema de otimização das métricas.

2.1 Formulação do Problema

Com o entendimento do problema e de suas variáveis, foi possível desenvolver uma possível formulação matemática, de modo a tornar possível a utilização de algoritmos de otimização, e encontrar a solução ótima. Abaixo está a modelagem desenvolvida:

$$\max_{\mathbf{X}} \quad \hat{y} = f(\mathbf{X}) \tag{2.1}$$

$$\text{s.a.} \quad L_{\min,j} \leq x_j \leq L_{\max,j}, \quad \forall j \in \{1,2,\ldots,p\} \tag{2.2}$$

$$x_{\text{Grau_API}} = C_{\text{API}} \tag{2.3}$$

$$x_{\text{Idade}} = C_{\text{Idade}} \tag{2.4}$$

$$x_{\text{PCS}} = C_{\text{PCS}} \tag{2.5}$$

$$x_{\text{Densidade GLP Gás}} = C_{\text{Densidade GLP Gás}} \tag{2.6}$$

$$x_{\text{Densidade GLP Líquido}} = C_{\text{Densidade GLP Líquido}} \tag{2.7}$$

$$x_{\text{Lâmina D'Água}} = C_{\text{Lâmina D'Água}} \tag{2.8}$$

$$x_{\text{Distância Poço k}} = C_{\text{Distância Poço k}} \tag{2.9}$$

$$x_{\text{Poços no Raio de 2 km}} = C_{\text{Poços no Raio de 2 km}} \tag{2.10}$$

$$x_j \in \mathbb{R}_+, \quad \forall j \in \{1,2,\ldots,p\} \tag{2.11}$$

Quem é k na equação 2.9? É o mesmo indice j?

Nesta modelagem, foi definida na equação (2.1) a função objetivo, que estabelece a meta de maximizar a produção estimada $\hat{y}$. A função $f(\mathbf{X})$ consiste na relação preditiva aprendida pelos algoritmos de *ML*, como *Linear Regression Forest* ou *LightGBM*, capaz de capturar interações entre as variáveis, sejam essas lineares ou não lineares. A definição da função objetivo apresentada veio com base no escopo desse trabalho, que busca utilizar tais modelos para encontrar aquele que melhor se adapte aos dados apresentados.

As variáveis deste modelo são representadas pelo vetor $\mathbf{X} = \{x_1, x_2, \ldots, x_p\}$, composto pelos parâmetros operacionais que podem ser manipulados para influenciar a vazão. O domínio definido para essas variáveis na equação (2.11) como reais não negativos ($\mathbb{R}_+$) reflete a natureza física de grandezas como vazões e intervalos temporais.

A equação 2.2 determina o intervalo das variáveis de decisão $x_j \in \mathbf{X}$. Tais variáveis devem respeitar os limites mínimos ($L_{\min}$) e máximos ($L_{\max}$) de segurança e capacidade dos equipamentos.

Por fim, as equações (2.3)-(2.10) determinam os parâmetros do problema, de modo que tais informações são relacionadas à um poço específico, e não podem ser alteradas.

2.2 Problema Linear

Os modelos lineares supervisionados assumem uma relação funcional paramétrica e aditiva entre uma matriz de atributos preditores e uma variável resposta contínua. O objetivo consiste em estimar o vetor de coeficientes $\beta \in \mathbb{R}^{p+1}$ que minimiza a soma dos *Residual Sum of Squares*/Soma dos Quadrados dos Resíduos (RSS), acrescida ou não de um termo de regularização para conter a variância das estimativas. A formulação geral de otimização irrestrita para essa classe de regressores é expressa por:

$$\min_{\beta \in \mathbb{R}^{p+1}} \quad J(\beta) = \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} \right) \right)^2 + \lambda \cdot R(\beta) \tag{2.12}$$

em que $y_i \in \mathbb{R}$ representa o valor escalar observado da variável resposta para a i-ésima instância ($i = 1, \ldots, n$), e $x_{ij} \in \mathbb{R}$ denota o valor associado ao j-ésimo atributo preditivo ($j = 1, \ldots, p$). O vetor de parâmetros a ser estimado decompõe-se no termo independente ou intercepto ($\beta_0 \in \mathbb{R}$) e nos pesos lineares associados a cada dimensão ($\beta_j \in \mathbb{R}$). O parâmetro $\lambda \geq 0$ atua como o hiperparâmetro de regularização, ditando a intensidade da penalidade sobre a magnitude dos coeficientes.

A partir da estrutura apresentada na equação 2.12, derivam-se três variantes fundamentais de regressão linear em função da definição adotada para o funcional $R(\beta)$:

- **Regressão Linear por *Ordinary Least Squares*/Mínimos Quadrados Ordinários (OLS):** Obtida definindo $\lambda = 0$. Sob essa condição, o ajuste depende estritamente da minimização dos desvios quadráticos amostrais. Trata-se de um estimador não tendencioso de variância mínima sob as hipóteses do Teorema de Gauss-Markov, porém suscetível à instabilidade numérica e sobreajuste na presença de multicolinearidade.
- **Regressão Ridge (Regularização L_2):** Configura-se aplicando a norma euclidiana quadrática dos pesos preditores, isto é, $R(\beta) = \|\beta_{1:p}\|_2^2 = \sum_{j=1}^{p} \beta_j^2$. A penalização quadrática contrai uniformemente os coeficientes em direção a zero, mitigando a variância do estimador frente a variáveis altamente correlacionadas, embora não realize a seleção esparsa de variáveis ($\beta_j \neq 0, \forall j$).
- **Regressão Lasso (Regularização L_1):** Estrutura-se a partir da penalização pela norma de Manhattan, definida por $R(\beta) = \|\beta_{1:p}\|_1 = \sum_{j=1}^{p} |\beta_j|$. Devido à geometria dos contornos da norma L_1, que contém vértices nos eixos das coordenadas, essa formulação força coeficientes de variáveis irrelevantes ou redundantes a assumirem exatamente o valor zero

para valores adequados de λ, atuando concomitantemente como estimador preditivo e mecanismo de seleção de atributos (*feature selection*).

Ressalta-se que o termo independente β_0 é comumente excluído da função de penalidade $R(\beta)$, assegurando que a penalização incida exclusivamente sobre as inclinações relativas às variáveis explicativas e preserve o ajuste médio da distribuição amostral.

2.3 Problema Não Linear

A fim de superar a rigidez funcional das abordagens lineares e modelar interações mais complexas entre os atributos, é necessário recorrer a modelos de aprendizado supervisionado não linear. De forma geral, esses algoritmos assumem que a variável contínua observada $y_i \in \mathbb{R}$ relaciona-se com o vetor de atributos preditores $\mathbf{x}_i \in \mathbb{R}^p$ por meio de uma função arbitrária $f : \mathbb{R}^p \to \mathbb{R}$ sujeita a ruído estocástico:

Definir variação de i!

$$y_i = f(\mathbf{x}_i) + \varepsilon_i, \quad \text{com } \mathbb{E}[\varepsilon_i \mid \mathbf{x}_i] = 0 \text{ e } \operatorname{Var}(\varepsilon_i \mid \mathbf{x}_i) = \sigma^2 \tag{2.13}$$

Em vez de restringir a busca a um hiperplano paramétrico estrito, o objetivo consiste em aproximar a função desconhecida $f(\cdot)$ dentro de um espaço de hipóteses $\mathscr{F}$, minimizando o risco empírico regularizado:

$$\min_{f \in \mathscr{F}} \quad \frac{1}{n} \sum_{i=1}^{n} \mathscr{L}(y_i, f(\mathbf{x}_i)) + \Omega(f) \tag{2.14}$$

em que $L(\cdot)$ representa a função de perda (como o erro quadrático ou a perda insensível) e $\Omega(f)$ impõe uma penalidade sobre a complexidade funcional para mitigar o sobreajuste.

Nesta pesquisa, foram avaliados cinco modelos não lineares, distribuídos em três famílias metodológicas de *ML*: algoritmos baseados em instâncias e vizinhança, algoritmos baseados em SVM, e algoritmos baseados em árvores de decisão.

2.3.1 Modelos baseados em Instâncias e Vizinhança

A família de modelos baseados em instâncias e vizinhança fundamenta-se no princípio do aprendizado preguiçoso (*lazy learning*), no qual não há uma fase de calibração de parâmetros globais ou estimação prévia de hiperplanos. O algoritmo investigado nesta categoria

foi o *K-Nearest Neighbors* (KNN), amplamente consolidado em problemas de classificação e adaptado para a regressão contínua (KAVLAKOGLU, 2021).

Dada uma nova observação $\mathbf{x}^* \in \mathbb{R}^p$, o modelo estima a variável de resposta contínua calculando a média aritmética dos valores observados entre os k vizinhos mais próximos no espaço vetorial de atributos:

$$\hat{f}_{\text{KNN}}(\mathbf{x}^*) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(\mathbf{x}^*)} y_i \tag{2.15}$$

em que $\mathcal{N}_k(\mathbf{x}^*)$ denota o conjunto de índices das k instâncias amostrais com menor distância em relação a $\mathbf{x}^*$. A proximidade métrica entre as instâncias no espaço $\mathbb{R}^p$ pode ser generalizada pela distância de Minkowski com parâmetro $q \geq 1$:

$$d_q(\mathbf{x}^*, \mathbf{x}_i) = \left(\sum_{j=1}^{p} |x_j^* - x_{ij}|^q \right)^{\frac{1}{q}} \tag{2.16}$$

A partir da formulação geral em (2.16), derivam-se métricas específicas em função do valor atribuído a q:

- **Distância Manhattan ($q = 1$):** baseada na norma ℓ_1, soma as diferenças absolutas em cada dimensão:

$$d_{\text{Manhattan}}(\mathbf{x}^*, \mathbf{x}_i) = \sum_{j=1}^{p} |x_j^* - x_{ij}| \tag{2.17}$$

- **Distância Euclidiana ($q = 2$):** correspondente à norma euclidiana padrão ℓ_2, adotada como configuração padrão neste trabalho:

$$d_{\text{Euclidiana}}(\mathbf{x}^*, \mathbf{x}_i) = \sqrt{\sum_{j=1}^{p} (x_j^* - x_{ij})^2} \tag{2.18}$$

A não linearidade do estimador manifesta-se pela partição local do domínio contínuo em células de Voronoi implícitas, permitindo que a resposta se adapte a superfícies de produção complexas sem hipóteses restritivas sobre a distribuição dos dados. Ressalta-se que, devido à sensibilidade intrínseca das métricas de distância em (2.16) à magnitude dos atributos preditores, a padronização das variáveis via `StandardScaler` no `Pipeline` foi estritamente indispensável para assegurar pesos homogêneos a todas as dimensões durante a busca dos vizinhos mais próximos.

2.3.2 Algoritmos baseados em SVM

O grupo de algoritmos baseados em SVM busca assegurar alta capacidade de generalização a partir de um número limitado de padrões de treinamento, fundamentando-se no princípio da *Structural Risk Minimization*/Minimização de Risco Estrutural (SRM). Tal princípio atua equilibrando simultaneamente a minimização do risco empírico e o controle da dimensão Vapnik–Chervonenkis (VC), a qual expressa a capacidade de representação do modelo por meio do tamanho máximo de um conjunto de dados passível de ser perfeitamente separado (ou rotulado) pela família de funções admitida (BASAK *et al.*, 2007).

O conceito de SVM foi formalizado por Vapnik (1995), estabelecendo que o estimador projeta o vetor de atributos de entrada $\mathbf{x}$ em um espaço de características de alta dimensionalidade $\mathscr{F}$ por meio de um mapeamento não linear a priori, ambiente no qual se constrói um hiperplano ótimo de separação que maximiza a margem geométrica entre os padrões.

No trabalho em questão, utilizou-se o algoritmo *Suport Vector Regression* (SVR), que estende a formulação original de classificação para a predição de variáveis contínuas, adotando-se especificamente a sua formulação não linear. Dada uma base de treinamento com l instâncias $\{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_l, y_l)\}$, onde $\mathbf{x}_i \in \mathbb{R}^p$ e $y_i \in \mathbb{R}$, o objetivo consiste em determinar uma função linear no espaço transformado, $f(\mathbf{x}) = \langle \omega, \Phi(\mathbf{x}) \rangle + b$, que apresente desvio máximo de ε em relação aos alvos observados y_i e mantenha a máxima regularidade possível (minimizando $\|\omega\|^2$), em que $\langle \cdot, \cdot \rangle_{\mathscr{F}}$ denota o produto escalar no espaço de características $\mathscr{F}$. Para tanto, adota-se a função de perda ε-insensível de Vapnik:

$$|\xi|_\varepsilon = \begin{cases} 0, & \text{se } |\xi| < \varepsilon \\ |\xi| - \varepsilon, & \text{caso contrário} \end{cases} \tag{2.19}$$

em que desvios contidos no intervalo $[-\varepsilon, +\varepsilon]$ não recebem penalização, conferindo imunidade a variações estocásticas nas séries temporais de vazão (BASAK *et al.*, 2007).

Para acomodar desvios que eventualmente ultrapassem os limites de tolerância do tubo, introduzem-se variáveis de folga ξ_i e ξ_i^* para erros positivos e negativos, formulando o problema de otimização primal convexo:

$$\min_{\omega,b,\xi,\xi^*} \quad \frac{1}{2}\|\omega\|^2 + C\sum_{i=1}^{l}(\xi_i + \xi_i^*) \tag{2.20}$$

$$\text{s.a.} \quad y_i - \langle \omega, \Phi(\mathbf{x}_i)\rangle - b \leq \varepsilon + \xi_i, \quad \forall i \in \{1,\ldots,l\} \tag{2.21}$$

$$\langle \omega, \Phi(\mathbf{x}_i)\rangle + b - y_i \leq \varepsilon + \xi_i^*, \quad \forall i \in \{1,\ldots,l\} \tag{2.22}$$

$$\xi_i, \xi_i^* \geq 0, \quad \forall i \in \{1,\ldots,l\} \tag{2.23}$$

onde a constante de regularização $C > 0$ estabelece o *trade-off* entre a regularidade de f e a tolerância aos desvios marginais.

A função de mapeamento não linear $\Phi : \mathbb{R}^p \to \mathscr{F}$ desempenha o papel central de projetar os vetores de atributos originais do espaço de entrada para um espaço de características de dimensão potencialmente infinita $\mathscr{F}$. A fundamentação teórica dessa transformação repousa no fato de que relações complexas e intrinsecamente não lineares no espaço original tornam-se passíveis de ajuste linear quando representadas nessa dimensionalidade superior (MüLLER *et al.*, 2001). Contudo, a avaliação explícita das coordenadas de $\Phi(\mathbf{x})$ é frequentemente inviável do ponto de vista analítico e computacional. Essa barreira é contornada pelo artifício do núcleo, no qual o produto interno $\langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j)\rangle_{\mathscr{F}}$ é calculado de maneira estritamente implícita no espaço original por meio da função de núcleo $k(\mathbf{x}_i, \mathbf{x}_j)$, dispensando o conhecimento direto da forma funcional exata de $\Phi(\cdot)$.

A resolução eficiente em alta dimensão fundamenta-se na formulação dual de Lagrange. Introduzindo os multiplicadores $\alpha_i, \alpha_i^* \geq 0$ (associados ao tubo de tolerância) e $\eta_i, \eta_i^* \geq 0$ (associados às folgas ξ_i, ξ_i^*), a função Lagrangiana L expressa-se por:

$$\begin{aligned} L = \quad & \frac{1}{2}\|\omega\|^2 + C\sum_{i=1}^{l}(\xi_i + \xi_i^*) - \sum_{i=1}^{l}\alpha_i(\varepsilon + \xi_i - y_i + \langle \omega, \Phi(\mathbf{x}_i)\rangle + b) \\ & - \sum_{i=1}^{l}\alpha_i^*(\varepsilon + \xi_i^* + y_i - \langle \omega, \Phi(\mathbf{x}_i)\rangle - b) - \sum_{i=1}^{l}(\eta_i\xi_i + \eta_i^*\xi_i^*) \end{aligned} \tag{2.24}$$

Pelas condições de ponto de sela para otimalidade, a anulação das derivadas parciais de L em relação às variáveis primais $(\omega, b, \xi_i, \xi_i^*)$ resulta em:

$$\frac{\partial L}{\partial b} = \sum_{i=1}^{l}(\alpha_i^* - \alpha_i) = 0 \tag{2.25}$$

$$\frac{\partial L}{\partial \omega} = \omega - \sum_{i=1}^{l}(\alpha_i - \alpha_i^*)\Phi(\mathbf{x}_i) = 0 \quad \Longrightarrow \quad \omega = \sum_{i=1}^{l}(\alpha_i - \alpha_i^*)\Phi(\mathbf{x}_i) \tag{2.26}$$

$$\frac{\partial L}{\partial \xi_i^{(*)}} = C - \alpha_i^{(*)} - \eta_i^{(*)} = 0 \tag{2.27}$$

Substituindo (2.25), (2.26) e (2.27) na Equação (2.24), obtém-se o problema quadrático dual:

$$\max_{\alpha,\alpha^*} \quad -\frac{1}{2}\sum_{i=1}^{l}\sum_{j=1}^{l}(\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*)k(\mathbf{x}_i,\mathbf{x}_j) - \varepsilon\sum_{i=1}^{l}(\alpha_i + \alpha_i^*) + \sum_{i=1}^{l} y_i(\alpha_i - \alpha_i^*) \tag{2.28}$$

$$\text{s.a.} \quad \sum_{i=1}^{l}(\alpha_i - \alpha_i^*) = 0 \tag{2.29}$$

$$0 \leq \alpha_i, \alpha_i^* \leq C, \quad \forall i \in \{1,\ldots,l\} \tag{2.30}$$

A função de predição final resulta da expansão por vetores de suporte expressa em (2.26):

$$\hat{f}_{\text{SVR}}(\mathbf{x}^*) = \sum_{i=1}^{l}(\alpha_i - \alpha_i^*)k(\mathbf{x}_i,\mathbf{x}^*) + b \tag{2.31}$$

Pelas condições de folga complementar de Karush-Kuhn-Tucker (KKT), os produtos entre variáveis duais e restrições primais anulam-se no ponto ótimo:

$$\alpha_i(\varepsilon + \xi_i - y_i + \langle\omega,\Phi(\mathbf{x}_i)\rangle + b) = 0 \tag{2.32}$$

$$\alpha_i^*(\varepsilon + \xi_i^* + y_i - \langle\omega,\Phi(\mathbf{x}_i)\rangle - b) = 0 \tag{2.33}$$

$$(C - \alpha_i)\xi_i = 0 \quad \text{e} \quad (C - \alpha_i^*)\xi_i^* = 0 \tag{2.34}$$

Dentre as propriedades analíticas destacadas por Basak *et al.* (2007), sobressaem-se:

1. **Esparsidade (*Sparsity*):** para amostras contidas no interior do tubo ($|f(\mathbf{x}_i) - y_i| < \varepsilon$), tem-se $\xi_i = \xi_i^* = 0$, implicando necessariamente $\alpha_i = \alpha_i^* = 0$. Apenas observações com resíduo igual ou superior a ε apresentam coeficientes não nulos, sendo denominadas *vetores de suporte*;

2. **Exclusão mútua:** como uma observação não pode violar simultaneamente as duas margens, decorre que $\alpha_i \cdot \alpha_i^* = 0$;
3. **Cálculo do termo de viés (b):** para vetores de suporte situados estritamente na margem livre ($0 < \alpha_i^{(*)} < C$), tem-se $\xi_i^{(*)} = 0$, permitindo isolar b a partir de (2.32) e (2.33):

$$b = \begin{cases} y_i - \sum_{j=1}^{l} (\alpha_j - \alpha_j^*) k(\mathbf{x}_j, \mathbf{x}_i) - \varepsilon, & \text{para } \alpha_i \in (0, C) \\ y_i - \sum_{j=1}^{l} (\alpha_j - \alpha_j^*) k(\mathbf{x}_j, \mathbf{x}_i) + \varepsilon, & \text{para } \alpha_i^* \in (0, C) \end{cases} \tag{2.35}$$

A escolha da função de núcleo (*kernel*) $k(\mathbf{x}_i, \mathbf{x}_j)$ determina a geometria do mapeamento implícito e a classe funcional do estimador. No presente trabalho, o espaço de busca hiperparamétrica avaliou quatro formulações mercerianas clássicas:

1. **Linear:**

$$k(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle \tag{2.36}$$

2. ***Radial Basis Function*/Função de Bases Radial (RBF):**

$$k(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|_2^2\right), \quad \gamma > 0 \tag{2.37}$$

3. **Polinomial:**

$$k(\mathbf{x}_i, \mathbf{x}_j) = \left(\gamma \langle \mathbf{x}_i, \mathbf{x}_j \rangle + r\right)^d, \quad \gamma > 0,\ d \in \mathbb{N}^* \tag{2.38}$$

4. **Sigmoide:**

$$k(\mathbf{x}_i, \mathbf{x}_j) = \tanh\left(\gamma \langle \mathbf{x}_i, \mathbf{x}_j \rangle + r\right) \tag{2.39}$$

em que γ governa a largura da influência local ou escala das projeções, r denota o termo independente de deslocamento e d representa o grau polinomial. Todos os hiperparâmetros estruturais (C e ε), bem como os parâmetros intrínsecos de cada família de núcleos (γ, r e d), foram sistematicamente calibrados por validação cruzada por meio de `GridSearchCV`.

Ademais, em virtude da sensibilidade às magnitudes relativas dos preditores — evidenciada tanto pela norma euclidiana presente em (2.37) quanto pelos produtos escalares sucessivos em (2.36), (2.38) e (2.39) —, a padronização das covariáveis via `StandardScaler` no fluxo do `Pipeline` foi mantida estritamente para todos os núcleos avaliados, assegurando estabilidade numérica e homogeneidade dimensional durante a otimização quadrática.

2.3.3 Algoritmos baseados em Árvores de Decisão

As árvores de decisão para regressão fundamentam-se no particionamento binário recursivo e hierárquico do espaço de atributos em sub-regiões ortogonais disjuntas, associando a cada nó terminal (folha) um valor constante determinado pela média amostral local das respostas. Conforme revisado historicamente por Loh (2014), a metodologia consolidou-se a partir de pioneiros como o *Automatic Interaction Detection* (AID) e, posteriormente, o *Classification and Regression Trees* (CART), nos quais a escolha da melhor divisão em cada nó decorre da busca exaustiva pelo atributo e ponto de corte que maximizem a redução da soma dos quadrados dos resíduos locais. Não obstante a sua elevada interpretabilidade estrutural e capacidade intrínseca de lidar com não linearidades, estimadores baseados em árvores individuais apresentam alta variância amostral e instabilidade numérica frente a pequenas perturbações nos dados de treinamento, fatores que impulsionaram historicamente a sua consolidação como estimadores-base em arquiteturas de comitês (*ensembles*).

No escopo deste trabalho, foram avaliados os seguintes algoritmos baseados em árvores: Random Forest, Gradient Boosting.

2.3.3.1 Random Forest

O algoritmo *Random Forest* fundamenta-se na extensão do paradigma de *bagging* aplicado a árvores de decisão, tendo sido formalizado originalmente por Breiman (2001). O modelo opera construindo uma coleção de estimadores $\{h(\mathbf{x}, \Theta_k), k = 1, \ldots, K\}$, denominados árvores de decisão, em que cada unidade é ajustada sobre uma partição de dados gerada por reamostragem com reposição (*bootstrap*) e os vetores aleatórios Θ_k determinam a amostragem independente de um subconjunto restrito de atributos em cada divisão de nó.

Considerando um problema de regressão em que as respostas observadas $Y \in \mathbb{R}$ são variáveis contínuas associadas a atributos $\mathbf{X} \in \mathbb{R}^p$, com amostra de treinamento $\mathscr{D}_n = \{(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)\}$ sorteada independentemente a partir da distribuição conjunta $(\mathbf{X}, Y)$, o erro quadrático médio de generalização para qualquer estimador $h(\mathbf{X})$ é definido formalmente por:

$$\mathrm{PE}^*(h) = \mathbb{E}_{\mathbf{X},Y}\left[(Y - h(\mathbf{X}))^2\right] \tag{2.40}$$

No contexto computacional finito, a predição da floresta corresponde à média aritmética simples

das predições pontuais emitidas pelas K árvores individuais:

$$\bar{h}(\mathbf{x}) = \frac{1}{K}\sum_{k=1}^{K} h(\mathbf{x}, \Theta_k) \tag{2.41}$$

Embora a representação de Breiman (2001) espelhe diretamente a rotina algorítmica executada na prática, a análise assintótica de suas propriedades estatísticas demanda uma formulação analítica fechada. Com esse propósito, Biau (2012) formalizou cada árvore individual como um estimador de partição linear local sobre o suporte amostral $[0,1]^p$. Seja $A_n(\mathbf{X};\Theta)$ a célula hiper-retangular única (folha terminal) que contém o ponto de consulta $\mathbf{X}$, a estimativa da árvore expressa-se por (BIAU, 2012):

$$m_n(\mathbf{X};\Theta) = \frac{\sum_{i=1}^{n} Y_i \mathbb{I}_{\{\mathbf{X}_i \in A_n(\mathbf{X};\Theta)\}}}{N_n(\mathbf{X};\Theta)} \mathbb{I}_{\mathscr{E}_n(\mathbf{X};\Theta)} \tag{2.42}$$

em que $N_n(\mathbf{X};\Theta) = \sum_{i=1}^{n} \mathbb{I}_{\{\mathbf{X}_i \in A_n(\mathbf{X};\Theta)\}}$ contabiliza o número de instâncias de treinamento contidas na partição de $\mathbf{X}$, e o evento $\mathscr{E}_n(\mathbf{X};\Theta) = \{N_n(\mathbf{X};\Theta) \neq 0\}$ atribui predição nula caso a célula terminal não contenha observações amostrais.

Definindo os pesos individuais $W_{n,i}(\mathbf{X};\Theta) = \frac{\mathbb{I}_{\{\mathbf{X}_i \in A_n(\mathbf{X};\Theta)\}}}{N_n(\mathbf{X};\Theta)} \mathbb{I}_{\mathscr{E}_n(\mathbf{X};\Theta)}$, a floresta agregada idealizada no limite assintótico ($K \to \infty$) resulta da esperança matemática condicional sobre a distribuição do parâmetro de aleatorização Θ (BIAU, 2012):

$$\bar{m}_n(\mathbf{X}) = \mathbb{E}_\Theta\left[m_n(\mathbf{X};\Theta)\right] = \sum_{i=1}^{n} \mathbb{E}_\Theta\left[W_{n,i}(\mathbf{X};\Theta)\right] Y_i \tag{2.43}$$

A formulação (2.43) evidencia que o *Random Forest* opera como um estimador por ponderação local adaptativa, no qual o peso atribuído a cada observação Y_i quantifica a probabilidade marginal de $\mathbf{X}_i$ compartilhar a mesma célula de particionamento com $\mathbf{X}$ ao longo do espaço induzido por Θ. Ademais, Biau (2012) demonstrou que esse mecanismo garante a consistência estatística do estimador e promove adaptação intrínseca à esparsidade: a taxa de convergência do erro quadrático médio depende estritamente do número de variáveis efetivamente informativas ($S \leq p$), tornando o algoritmo robusto à presença de atributos ruidosos ou redundantes no espaço de entrada.

2.3.3.2 *Gradient Boosting*

Diferentemente do paradigma de *bagging*, no qual os estimadores são construídos de maneira independente e paralela para reduzir a variância, o *Gradient Boosting*, formalizado por Friedman (2001), fundamenta-se na aproximação de funções sob a perspectiva de otimização numérica no espaço funcional. Dada uma amostra de treinamento $\{\mathbf{x}_i, y_i\}_{i=1}^{N}$, o objetivo consiste em determinar uma função aproximadora $F^*(\mathbf{x})$ que minimize o valor esperado de uma função de perda diferenciável $\Psi(y, F(\mathbf{x}))$ sobre a distribuição conjunta de $(\mathbf{x}, y)$:

$$F^*(\mathbf{x}) = \arg\min_{F(\mathbf{x})} \mathbb{E}_{y,\mathbf{x}} \left[\Psi(y, F(\mathbf{x}))\right] \tag{2.44}$$

Para tornar o problema tratável em amostras finitas, restringe-se $F(\mathbf{x})$ a uma expansão aditiva parametrizada de estimadores-base (*weak learners*) $h(\mathbf{x}; \mathbf{a}_m)$, estruturados como árvores de decisão de tamanho reduzido:

$$F(\mathbf{x}; \{\beta_m, \mathbf{a}_m\}_{m=0}^{M}) = \sum_{m=0}^{M} \beta_m h(\mathbf{x}; \mathbf{a}_m) \tag{2.45}$$

em que $\mathbf{a}_m$ engloba os parâmetros estruturais de particionamento da m-ésima árvore (variáveis de divisão, pontos de corte e médias dos nós terminais) e β_m denota o coeficiente de expansão.

Partindo de uma estimativa inicial constante $F_0(\mathbf{x}) = \arg\min_{\rho} \sum_{i=1}^{N} \Psi(y_i, \rho)$, o algoritmo adota uma estratégia gulosa passo a passo análoga ao método de descida mais íngreme. Em cada iteração $m \in \{1, \ldots, M\}$, calcula-se a direção do gradiente negativo não restrito da função de perda em relação ao modelo acumulado $F_{m-1}(\mathbf{x})$, originando as chamadas pseudo-respostas (ou pseudo-resíduos) $\tilde{y}_i$:

$$\tilde{y}_i = -\left[\frac{\partial \Psi(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)}\right]_{F(\mathbf{x})=F_{m-1}(\mathbf{x})}, \quad \forall i \in \{1, \ldots, N\} \tag{2.46}$$

No caso particular de regressão por mínimos quadrados ordinários, em que $\Psi(y, F) = \frac{1}{2}(y - F)^2$, a Equação (2.46) reduz-se diretamente aos resíduos correntes do comitê, $\tilde{y}_i = y_i - F_{m-1}(\mathbf{x}_i)$. Em seguida, ajusta-se uma nova árvore de decisão $h(\mathbf{x}; \mathbf{a}_m)$ por mínimos quadrados para aproximar a direção dos pseudo-resíduos e determina-se o comprimento ótimo do passo ρ_m via busca linear:

$$\mathbf{a}_m = \arg\min_{\mathbf{a},\beta} \sum_{i=1}^{N} [\tilde{y}_i - \beta h(\mathbf{x}_i;\mathbf{a})]^2 \tag{2.47}$$

$$\rho_m = \arg\min_{\rho} \sum_{i=1}^{N} \Psi\left(y_i, F_{m-1}(\mathbf{x}_i) + \rho h(\mathbf{x}_i;\mathbf{a}_m)\right) \tag{2.48}$$

Para mitigar o *overfitting* decorrente da adição sucessiva de árvores, Friedman (2001) introduz um mecanismo de regularização por encolhimento proporcional (*shrinkage*), escalonando a contribuição de cada novo estimador por um parâmetro $0 < \nu \leq 1$ (taxa de aprendizado), o que resulta na regra de atualização iterativa:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\rho_m h(\mathbf{x};\mathbf{a}_m), \quad 0 < \nu \leq 1 \tag{2.49}$$

estabelecendo um compromisso direto entre a magnitude de ν e o número total de iterações M necessárias para a convergência do comitê.

A partir do arcabouço clássico de Friedman (2001), implementações modernas como o XGBoost (*eXtreme Gradient Boosting*) e o LightGBM (*Light Gradient Boosting Machine*) introduziram aprimoramentos analíticos e computacionais voltados à regularização estrutural e à escalabilidade.

Proposto por Chen e Guestrin (2016), o XGBoost define o espaço de árvores de regressão CART como $\mathscr{F} = \{f(\mathbf{x}) = w_{q(\mathbf{x})}\}$, em que a estrutura $q : \mathbb{R}^p \to \{1,\ldots,T\}$ mapeia cada observação ao índice de seu respectivo nó terminal e $\mathbf{w} \in \mathbb{R}^T$ representa o vetor de pesos associados às T folhas da árvore. O algoritmo distingue-se da formulação tradicional de primeira ordem pela incorporação de um termo de penalização explícito sobre a complexidade do modelo e pelo emprego de uma aproximação em série de Taylor de segunda ordem. Na t-ésima iteração, busca-se o estimador $f_t \in \mathscr{F}$ que minimiza o objetivo regularizado:

$$\mathscr{L}^{(t)} = \sum_{i=1}^{N} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)\right) + \Omega(f_t), \quad \text{com} \quad \Omega(f_t) = \gamma T + \frac{1}{2}\lambda\|\mathbf{w}\|^2 \tag{2.50}$$

em que l é uma função de perda convexa diferenciável que calcula a diferença entre o valor alvo y_i e a predição $\hat{y}_i$, γ penaliza a quantidade de folhas T e λ controla a regularização L_2 sobre a magnitude dos pesos terminais. Expandindo a função de perda em série de Taylor até a segunda ordem em torno de $\hat{y}^{(t-1)}$ e removendo os termos constantes, obtém-se o objetivo simplificado:

$$\tilde{\mathscr{L}}^{(t)} = \sum_{i=1}^{N} \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \tag{2.51}$$

no qual $g_i = \partial_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ e $h_i = \partial^2_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ denotam as estatísticas de gradiente de primeira e segunda ordem, respectivamente. Definindo $I_j = \{i \mid q(\mathbf{x}_i) = j\}$ como o conjunto de instâncias alocadas na folha j, calcula-se analiticamente o peso ótimo w_j^* e o escore de qualidade estrutural correspondente:

$$w_j^* = -\frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}, \qquad \tilde{\mathscr{L}}^{(m)}(q) = -\frac{1}{2} \sum_{j=1}^{T} \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} + \gamma T \tag{2.52}$$

A partir da Equação (2.52), a seleção gulosa de pontos de corte avalia a redução da perda $\mathscr{L}_{\text{split}}$ resultante da partição de um nó $I = I_L \cup I_R$ em subnós esquerdo (I_L) e direito (I_R):

$$\mathscr{L}_{\text{split}} = \frac{1}{2} \left[\frac{\left(\sum_{i \in I_L} g_i \right)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{\left(\sum_{i \in I_R} g_i \right)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{\left(\sum_{i \in I} g_i \right)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma \tag{2.53}$$

Adicionalmente ao objetivo regularizado e ao encolhimento por taxa de aprendizado, o XGBoost incorpora a subamostragem aleatória de atributos inspirada no Random Forest, algoritmos conscientes de esparsidade e esboços de quantis ponderados pelas estatísticas de segunda ordem h_i para discretização eficiente de atributos contínuos.

Embora o *XGBoost* mitigue o custo de ordenação por meio de estruturas de blocos em memória e quantis ponderados, a complexidade computacional para construir os histogramas e avaliar a Equação (2.53) permanece proporcional tanto ao número total de observações N quanto à dimensionalidade de atributos p. Visando superar esse gargalo em bases de dados de larga escala sem comprometer a acurácia preditiva, Ke *et al.* (2017) propuseram o algoritmo LightGBM.

O LightGBM preserva integralmente a expansão de Taylor de segunda ordem e a função objetivo regularizada expressas nas Equações (2.51 - 2.53), mas introduz três inovações estruturais e algorítmicas:

1. **Particionamento Baseado em Histogramas e Crescimento *Leaf-wise*:** Os atributos contínuos são discretizados previamente em k compartimentos inteiros, reduzindo a complexidade de busca do ponto de corte de $\mathscr{O}(N \cdot p)$ para $\mathscr{O}(k \cdot p)$, além de permitir a obtenção

do histograma de um nó irmão por simples subtração vetorial em relação ao nó pai. Adicionalmente, em contraste com a estratégia tradicional de expansão por nível de profundidade, o LightGBM adota o crescimento orientado às folhas, particionando iterativamente apenas a folha terminal que proporciona o maior ganho global $\mathscr{L}_{\text{split}}$ em toda a árvore, sujeito a um limite máximo de profundidade para evitar sobreajuste;

2. ***Gradient-based One-Side Sampling*** **(GOSS):** Fundamenta-se na premissa teórica de que instâncias associadas a gradientes de primeira ordem $|g_i|$ de pequena magnitude já se encontram bem ajustadas pelo comitê corrente, contribuindo marginalmente para o ganho de informação. Em cada iteração, o método GOSS ordena as observações de forma decrescente por $|g_i|$, retém integralmente o subconjunto A correspondente à fração $a \times 100\%$ de instâncias com os maiores gradientes e sorteia aleatoriamente um subconjunto B de tamanho $b \times |A^c|$ dentre o complemento de instâncias com gradientes reduzidos. Para preservar a distribuição original da perda ao avaliar os candidatos a ponto de corte d sobre o atributo j, os gradientes pertencentes a B são amplificados pelo fator constante $\frac{1-a}{b}$, resultando no estimador de ganho aproximado $\tilde{V}_j(d)$:

$$\tilde{V}_j(d) = \frac{1}{N}\left[\frac{\left(\sum_{x_i \in A_l} g_i + \frac{1-a}{b}\sum_{x_i \in B_l} g_i\right)^2}{n_l^j(d)} + \frac{\left(\sum_{x_i \in A_r} g_i + \frac{1-a}{b}\sum_{x_i \in B_r} g_i\right)^2}{n_r^j(d)}\right] \tag{2.54}$$

em que $A_l = \{x_i \in A \mid x_{ij} \leq d\}$, $A_r = \{x_i \in A \mid x_{ij} > d\}$, $B_l = \{x_i \in B \mid x_{ij} \leq d\}$, $B_r = \{x_i \in B \mid x_{ij} > d\}$, e os denominadores $n_l^j(d)$ e $n_r^j(d)$ contabilizam o total de observações alocadas aos subnós esquerdo e direito, respectivamente;

3. ***Exclusive Feature Bundling*** **(EFB):** Em espaços de alta dimensão com presença de esparsidade, múltiplos atributos são mutuamente exclusivos, isto é, raramente assumem valores não nulos de maneira simultânea. O método EFB reduz a quantidade efetiva de atributos ao fundir variáveis mutuamente exclusivas em um único feixe, deslocando os intervalos de seus *bins* originais por constantes de compensação para preservar a identificabilidade de cada variável. A determinação dos feixes ótimos é reduzida a um problema de coloração de grafos *NP-difícil* — no qual os vértices representam os atributos e as arestas ponderam os conflitos de não exclusividade —, resolvido eficientemente por uma heurística gulosa com taxa de conflito máxima tolerada.

2.4 Métricas

Por fim, há também a necessidade de se otimizar as métricas de cada um dos modelos, visto que esses determinarão o quanto o modelo se adequa ao problema, e o quanto ele consegue predizer os valores da variável objetivo. Sendo assim, abaixo serão apresentadas as métricas utilizadas e que foram otimizadas:

- **Coeficiente de Determinação (R^2):** O R^2 mede a proporção da variância total na variável alvo que é explicada pelo modelo. É a métrica primária de precisão.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} = 1 - \frac{\text{RSS}}{\text{TSS}} \tag{2.55}$$

  Onde RSS é a Soma dos Quadrados dos Resíduos (erro do modelo) e *Total Sum of Squares* (TSS) é a variância total dos dados. Um R^2 próximo de 1 indica um ajuste excelente.

- **Raiz do Erro Quadrático Médio (RMSE):** O *Root Mean Squared Error*/Raiz do Erro Quadrático Médio (RMSE) é a principal métrica de erro, representando a magnitude média dos desvios. É a raiz quadrada da média dos erros quadrados, mantendo a unidade de medida original (bbl/dia) para interpretação prática.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{2.56}$$

  A função quadrática dentro da raiz penaliza erros grandes de forma desproporcional, tornando o RMSE sensível a *outliers*.

- **Erro Absoluto Médio (MAE):** O *Mean Absolute Error*/Erro Absoluto Médio (MAE) mede a média dos erros em valor absoluto.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{2.57}$$

  Por não elevar o erro ao quadrado, o MAE é mais robusto contra *outliers* do que o RMSE e fornece uma estimativa de erro mais intuitiva.

- **Diferença do Coeficiente de Determinação (ΔR^2):** Esta métrica avalia a capacidade de **generalização** do modelo, sendo essencial para identificar o *overfitting*.

$$\Delta R^2 = R^2_{\text{Treino}} - R^2_{\text{Teste}} \tag{2.58}$$

  Um ΔR^2 próximo de zero indica que o desempenho do modelo no conjunto de teste é similar ao do treino (boa generalização). Um valor positivo alto é um forte indicador de que o modelo memorizou os dados de treino, perdendo poder preditivo em dados não vistos.

3 FUNDAMENTAÇÃO TEÓRICA

Esta seção estabelece o arcabouço teórico e o estado da arte necessários para a compreensão e desenvolvimento da presente pesquisa, abrangendo a aplicação de conceitos de PO e de modelos de *ML* como ferramentas de otimização.

Pesquisa Operacional

3.1 Fundamentos de PO

A PO é uma área do conhecimento aplicada a problemas envolvendo como conduzir e coordenar as chamadas operações (ou ativadades) em um determinado processo, sendo largamente utilizada nas mais distintas áreas, com suas origens sendo atribuídas aos primórdios da Segunda Guerra Mundial. (HILLIER; LIEBERMAN, 2013).

O estudo de um determinado problema, utilizando técnicas de PO envolve as seguintes fases (HILLIER; LIEBERMAN, 2013):

1. Definir o problema de interesse
2. Coletar dados.
3. Formular um modelo matemático para representar o problema.
4. Desenvolver um procedimento computacional a fim de derivar soluções para o problema a partir do modelo.
5. Testar o modelo e aprimorá-lo conforme necessário.
6. Preparar-se para a aplicação contínua do modelo conforme prescrito pela gerência.
7. Implementar computacionamente.

De acordo com (HILLIER; LIEBERMAN, 2013), para a formulação matemática do problema é necessário definir os seguintes componentes, com essas sendo essenciais para traduzir a questão gerencial em um problema de otimização solucionável:

- **Variáveis de Decisão:** Representam as escolhas que podem ser manipuladas pelo modelo para buscar o resultado ótimo.
- **Parâmetros:** Valores fixos no problema.
- **Restrições:** Limites físicos, regulatórios ou de recursos do problema que definem a região de soluções viáveis.
- **Função Objetivo:** O critério de desempenho a ser maximizado ou minimizado, a depender do problema em questão.

Cada problema pode ser classificado de diferentes formas com base em diferentes

aspectos, tais classificações serão abordadas nas seguintes subsseções.

3.2 Fundamentos de Limpeza de Dados para Modelagem

A precisão dos modelos de *ML* é fundamentalmente dependente da qualidade dos dados de treinamento. A literatura demonstra que a coleta massiva de dados, especialmente em grandes volumes, resulta em datasets "sujos"que podem comprometer a acurácia dos resultados de predição. A limpeza de dados é essencial para garantir que a informação esteja precisa e uniforme, resolvendo problemas como incompletude, inconsistência e duplicação (RIDZUAN; Wan Zainon, 2019).

A ausência de tratamento para valores faltantes ou erros pode gerar incertezas no dataset e produzir resultados distintos e, potencialmente, equivocados para a tomada de decisão. O processo de limpeza de dados é uma etapa complexa e crucial, que tipicamente envolve as seguintes cinco fases (RIDZUAN; Wan Zainon, 2019):

1. **Data Analysis (*Análise de Dados*):** É a fase de auditoria, na qual o objetivo é identificar e obter metadados sobre todas as anomalias, erros e inconsistências presentes no banco de dados.
2. **Definition of transformation workflow (*Definição do Fluxo de Trabalho de Transformação*):** Nesta etapa, é definida a sequência de operações e regras de mapeamento necessárias para a detecção e correção das anomalias identificadas na fase anterior.
3. **Verification (*Verificação*):** Consiste na avaliação da correção e da eficácia do fluxo de trabalho de transformação, frequentemente exigindo a interação com especialistas do domínio para validar as transformações aplicadas.
4. **Transformation (*Transformação*):** É a execução dos passos de correção. Os dados são transformados e atualizados utilizando as regras definidas no fluxo de trabalho.
5. **Backflow of cleaned data (*Retorno dos Dados Limpos*):** Fase final onde os dados sujos originais são substituídos pelos dados limpos e validados, garantindo que o dataset de entrada para a modelagem seja de alta qualidade.

No contexto deste trabalho, a garantia da alta qualidade dos dados utilizados foi um pré-requisito crucial para o treinamento robusto dos modelos *surrogate* propostos. O processo de limpeza e preparação do *dataset* incluiu os seguintes passos:

- **Estrutura e Consistência:** Padronização e renomeação de colunas (ex: 'Grau API' para 'Grau_API') e remoção de colunas redundantes ou com baixa variância (como 'Nome

Poço ANP' e outras colunas de vazão não essenciais).

- **Limpeza de Dados:** Remoção de registros duplicados para garantir a integridade.
- **Tratamento de *Outliers*:** Utilização do algoritmo *IsolationForest* para identificar *outliers*, sendo um algoritmo baseado em árvores, que faz o isolamento dos valores discripantes através de particionamentos aleatórios, levando em conta que tais valores exigem menos divisões para serem separados dos demais valores (LIU *et al.*, 2008).
- **Engenharia de *Features*:** Incorporação de atributos espaciais e operacionais provenientes de bases cadastrais complementares, com o objetivo de enriquecer a representação física dos poços e a capacidade preditiva dos modelos.

3.3 Fundamentos de *ML*

ML é um subcampo da IA cujo objetivo principal é o desenvolvimento de técnicas computacionais que permitam a construção de sistemas capazes de adquirir conhecimento de forma automática, de forma que um sistema de aprendizado é essencialmente um programa de computador que toma decisões baseado em experiências acumuladas através da solução de problemas anteriores (MONARD; BARANAUSKAS, 2003).

Existem diferentes paradigmas de aprendizado, sendo o **Aprendizado Supervisionado** o mais utilizado em tarefas de regressão, como as aplicadas neste trabalho para a otimização da produção de poços de petróleo. Neste paradigma, o sistema recebe um conjunto de exemplos de treino, onde cada exemplo consiste num par entrada-saída desejada, permitindo que o algoritmo aprenda a mapear novas entradas com base no padrão identificado (MONARD; BARANAUSKAS, 2003).

A versatilidade desses paradigmas permitiu que o *ML* se consolidasse como uma ferramenta científica transversal, sendo aplicada com sucesso em domínios que variam desde a genômica e microbiologia até a engenharia de reservatórios (ASNICAR *et al.*, 2024). No entanto, a eficácia desses modelos em cenários complexos não são provenientes apenas da escolha do algoritmo, mas da implementação de um fluxo de trabalho rigoroso que prioriza a qualidade dos dados e a validação estatística. Essa perspectiva interdisciplinar reforça que, para que um modelo atue como um emulador confiável de fenômenos físicos — como a vazão de poços de petróleo —, é imprescindível a adoção de protocolos estritos de pré-processamento e limpeza de dados, visando garantir a generalização e evitar o *overfitting* (ASNICAR *et al.*, 2024).

3.3.1 Generalização e Overfitting

Um dos maiores desafios no treinamento de modelos de *ML* é garantir a sua capacidade de generalização, ou seja, a habilidade do sistema em realizar predições corretas para dados novos que não foram utilizados durante a etapa de treinamento (MONARD; BARANAUSKAS, 2003). Quando um modelo falha nesse aspecto, ocorre frequentemente o fenômeno do *overfitting* (sobreajuste).

O *overfitting* acontece quando o algoritmo "decora"as características específicas e os ruídos do conjunto de treinamento, apresentando um desempenho excelente nesta etapa, mas falhando ao ser avaliado em dados desconhecidos (ASNICAR *et al.*, 2024). Segundo Asnicar *et al.* (2024), um modelo sobreajustado pode ser enganoso, apresentando métricas de validação interna satisfatórias que não se sustentam na prática, o que compromete a sua utilidade em casos reais.

Para mitigar esse risco e assegurar que o modelo identifique apenas os padrões subjacentes reais, é fundamental adotar práticas rigorosas de validação e pré-processamento. Neste estudo, a aplicação do método de Intervalo Interquartil (IQR) para a remoção de *outliers* e o uso de técnicas de amostragem aleatória (detalhadas no Capítulo 4) foram estratégias essenciais para reduzir o ruído nos dados e, consequentemente, prevenir o *overfitting*, garantindo a robustez do modelo *surrogate* para a otimização de poços.

3.4 Modelos *Surrogate* na Otimização de Sistemas de Produção

Modelos *surrogate* — também referidos na literatura como modelos de resposta aproximada, metamodelos ou emuladores — são aproximações matemáticas de modelos de simulação numericamente intensivos (ASHER *et al.*, 2015). A premissa fundamental desta abordagem é a substituição de um simulador de alta fidelidade, que exige alto custo computacional e tempo de execução elevado, por um modelo estatístico ou computacional mais simples que seja capaz de mimetizar o comportamento do código original com precisão aceitável, mas a uma fração do custo original (ASHER *et al.*, 2015; ŠTUREK; LAZAROVA-MOLNAR, 2025).

De acordo com a taxonomia proposta por Asher *et al.* (2015), os modelos *surrogate* podem ser classificados em três categorias principais:

- **Modelos de Fidelidade Reduzida (*Lower-fidelity*):** Versões simplificadas do modelo físico, utilizando malhas mais grossas ou simplificações das equações governantes.

- **Modelos de Resposta de Baixa Ordem (*Reduced-order*):** Modelos que reduzem a dimensionalidade do sistema original preservando sua dinâmica essencial.
- **Modelos Baseados em Dados (*Data-driven*):** Também conhecidos como "caixa-preta", estes modelos utilizam técnicas de Aprendizado de Máquina para mapear a relação entre as entradas e saídas do simulador original, sem o conhecimento explícito da física interna do sistema.

Este trabalho foca na terceira categoria, utilizando *ML* para construir emuladores baseados em dados. Como destacado por Šturek e Lazarova-Molnar (2025), esses modelos são essenciais para viabilizar simulações em tempo real e ciclos de otimização iterativos em ambientes de Indústria 4.0, onde a agilidade na tomada de decisão é um requisito crítico.

3.5 Formalização Matemática dos Modelos de Aprendizado de Máquina

Conforme discutido na Seção 3.4, os modelos baseados em dados utilizam algoritmos de Aprendizado de Máquina para mapear as relações entre as variáveis de entrada e saída. Nesta seção, apresenta-se a fundamentação matemática dos modelos empregados para a construção do *surrogate*, abrangendo desde regressões lineares até arquiteturas complexas de redes neurais e *ensembles*.

No paradigma de aprendizado supervisionado, o objetivo é encontrar uma função de mapeamento f tal que $y = f(\mathbf{x}) + \varepsilon$, minimizando uma **Função de Perda**, como o *Mean Squared Error*/Erro Quadrático Médio (MSE), para garantir a capacidade de generalização e evitar o *overfitting* (ASNICAR *et al.*, 2024; MONARD; BARANAUSKAS, 2003).

3.5.1 Regressores Lineares e Regularização

Os modelos lineares fundamentam-se na premissa de que a variável de saída pode ser expressa como uma combinação linear das variáveis de entrada: $\hat{y} = w_0 + \sum_{i=1}^{n} w_i x_i$ (JAMES *et al.*, 2013). Para mitigar o risco de *overfitting* e controlar a magnitude dos coeficientes, aplicam-se técnicas de regularização que penalizam a complexidade do modelo:

- **LinearRegression:** Implementa o método de OLS, buscando minimizar a soma dos resíduos quadrados sem a aplicação de penalidades adicionais (JAMES *et al.*, 2013).
- **Lasso (L_1) e Ridge (L_2):** O modelo *Ridge* introduz uma penalidade proporcional ao quadrado dos pesos ($\lambda||w||_2^2$), enquanto o *Lasso* utiliza a norma L_1 ($\lambda||w||_1$) (JAMES *et*

al., 2013). A característica distintiva do *Lasso* é sua capacidade de realizar a seleção de variáveis, reduzindo a zero os coeficientes de preditores menos relevantes.

3.5.2 Modelos de Vizinhança e Suporte (KNN e SVR)

- **KNN:** É um método não-paramétrico que baseia suas predições na similaridade local. A saída para uma nova instância é calculada como a média das saídas observadas nos k vizinhos mais próximos dentro do espaço euclidiano de características (MONARD; BARANAUSKAS, 2003; JAMES *et al.*, 2013).
- **SVR:** Originário da teoria de suporte estatístico, o SVR busca encontrar um hiperplano de regressão que mantenha a maior parte dos dados dentro de uma margem de tolerância ε. O uso de funções de *kernel* permite que o modelo mapeie as entradas em espaços de alta dimensão, capturando relações não-lineares complexas (HASTIE *et al.*, 2009; MONARD; BARANAUSKAS, 2003).

3.5.3 Modelos Baseados em Árvores e Ensembles (Random Forest e XGBoost)

Os métodos de conjunto (*ensembles*) combinam múltiplas árvores de decisão para produzir um modelo preditivo mais robusto.

- **Random Forest:** Baseia-se no princípio de *Bagging* (*Bootstrap Aggregating*), onde diversas árvores são treinadas de forma independente em subamostras dos dados. A predição final resulta da média dessas subestimativas, o que reduz drasticamente a variância sem aumentar o viés (BREIMAN, 2001; JAMES *et al.*, 2013).
- **XGBoost:** Representa uma implementação otimizada de *Gradient Boosting*. Diferente do *Bagging*, as árvores são construídas sequencialmente para minimizar os erros residuais das árvores predecessoras por meio do gradiente da função de perda, incorporando termos de regularização para assegurar a generalização do modelo (CHEN; GUESTRIN, 2016).

4 PROPOSTA E METODOLOGIA

Neste capítulo, apresentam-se a proposta central e os procedimentos metodológicos adotados para a execução dos experimentos computacionais deste trabalho. Ressalta-se que todos os procedimentos e rotinas de cálculo foram desenvolvidos utilizando a linguagem Python.

A proposta deste trabalho consiste no desenvolvimento e na validação de um ecossistema de modelos de *ML* capaz de emular o comportamento de simuladores físicos de poços de petróleo, permitindo a predição de vazões e a otimização de cenários operacionais. Para a viabilização desta proposta, definem-se as seguintes frentes de atuação:

- Analisar o comportamento dos dados e a relação entre as variáveis físicas por meio de matrizes de correlação, identificando o grau de dependência entre elas e evitando possíveis enviesamentos no modelo.
- Avaliar a natureza do problema (linear ou não linear) com base no desempenho das métricas obtidas, utilizando esses resultados para orientar a escolha das arquiteturas de *ML* mais eficazes.
- Treinar e comparar diferentes algoritmos de *ML*, selecionando aquele que apresente a melhor precisão e capacidade de generalizar para novos cenários de produção.
- Consolidar os resultados em um trabalho técnico que contribua para a literatura da área e sirva de base sólida para a dissertação de mestrado.

No que tange à metodologia, a etapa inicial consistiu na extração de dados de produção de poços de petróleo *offshore* situados em diversas bacias brasileiras. Esses dados foram obtidos por meio do sistema de CDP da Petrobras, que organiza e disponibiliza os registros com periodicidade mensal. Para compor a base deste estudo, foram selecionados os arquivos referentes ao intervalo entre janeiro de 2018 e dezembro de 2025.

Devido à padronização de colunas e formatos mantida pela plataforma, os arquivos mensais foram importados e consolidados em um único *dataframe* utilizando a biblioteca Pandas da linguagem Python. A escolha desta biblioteca justifica-se pela sua eficiência na manipulação de grandes volumes de dados estruturados e pelo suporte a operações complexas de limpeza e tratamento, fundamentando-se nos conceitos discutidos na Seção 3.2. Com as funcionalidades dessa biblioteca, foi utilizado um *script* que foi responsável pela remoção de atributos considerados desnecessários para a modelagem, categorizados da seguinte forma:

- **Dados Administrativos e Geográficos:** Variáveis como "Estado", "Bacia", "Operador", "Nome Poço Operador", "Número do Contrato"e informações sobre instalações ("Insta-

lação Destino", "Tipo Instalação") foram removidas. Esses atributos funcionam apenas como identificadores ou metadados geográficos, não possuindo correlação física direta com as dinâmicas de produção que o modelo *surrogate* visa emular.

- **Metadados de Controle e Sistema:** Colunas como "Período da Carga", "Corrente"e "Data de atualização"foram descartadas por tratarem-se de registros temporais de auditoria interna da plataforma de CDP, sendo irrelevantes para o comportamento produtivo dos poços.
- **Composição Química de Alta Granularidade:** A análise detalhada da composição molar do gás (frações de metano, etano, propano até undecanos, além de gases inertes) e as frações de destilados foram excluídas. A manutenção desses atributos de alta granularidade aumentaria excessivamente a complexidade do modelo, podendo introduzir ruído e dificultar a generalização para diferentes cenários de reservatório.
- **Variáveis Redundantes ou de Escopo Secundário:** Métricas de vazão secundárias, como "Condensado (bbl/dia)"e a distinção entre "Gás Natural Assoc/N Assoc", foram removidas para evitar a colinearidade com as variáveis alvo principais, simplificando a arquitetura do modelo sem perda de fidelidade na representação do sistema.

Após a seleção de atributos, foi realizada a adequação dos tipos de dados das colunas remanescentes no *dataframe* do Pandas. Com exceção de três variáveis, uma contendo o nome do poço registrado pela Petrobras, uma com o nome do campo no qual o poço está instalado, e outra contendo o período em que os dados daquela linha foram registrados (mês e ano), as demais colunas foram convertidas para o formato numérico, garantindo a compatibilidade com os algoritmos de aprendizado de máquina.

Uma etapa crítica nesta fase foi a conversão do separador decimal. Visto que os dados brutos seguiam o padrão regional brasileiro (uso de vírgula), foi implementada uma rotina de tratamento para a substituição sistemática da vírgula pelo ponto. Essa normalização sintática é essencial para que o interpretador Python reconheça os registros como valores de ponto flutuante (*float*), permitindo que o Pandas processe as colunas tanto como variáveis preditoras quanto como variáveis alvo.

Concluída a correção dos tipos, realizou-se o tratamento de dados ausentes por meio da exclusão de todas as instâncias que continham valores nulos (*NaN - Not a Number*). Esta ação visou mitigar o risco de erros durante a etapa de treinamento e assegurar a integridade estatística do conjunto de dados. Ressalta-se que a remoção das linhas nulas foi executada propositalmente

após a conversão tipológica; no Pandas, objetos nulos em colunas numéricas são tratados como ponto flutuante, o que permitiu que o tratamento de valores faltantes fosse realizado de forma consistente com a estrutura final do *dataframe*.

Para complementar a preparação do *dataframe* e enriquecer o conjunto de variáveis preditoras, realizou-se uma etapa de engenharia de atributos (*feature engineering*). Esta fase envolveu a integração do *dataset* principal com dois novos conjuntos de dados, um disponibilizado pelo CDP contendo informações cadastrais dos poços, e outro disponibilizado pelo site do Gov.

No primeiro conjunto de dados foi possível realizar o cruzamento entre as bases, utilizando o nome do poço como chave de ligação, extraindo as datas de início de operação de cada unidade e sincronizando com as datas dos registros mensais de produção. Dessa forma, foi possível calcular o delta temporal de atividade de cada poço. Essa nova variável, denominada "Idade", armazena o número total de dias decorridos desde o início da operação até o momento do registro, fornecendo ao modelo uma métrica contínua do tempo de vida e do estágio de maturação do poço. Além disso, foi possível obter a informação da "lâmina d'água"de cada um dos poços, com essa nova variável representando a distância exata entre a superfície da água e o fundo do mar, sendo uma informação que pode vir a contribuir com a qualidade de predição dos modelos.

Já no segundo conjunto de dados, foi possível obter dados acerca do preço de referência do petróleo em cada um dos meses analisados, sendo feita a segmentação dos preços com base no nome do Campo em que está sendo extraído o petróleo, e essa última informação também foi utilizada para realizar o cruzamento dos dados.

Com isso, as colunas utilizadas para os cruzamentos — nome do poço, nome do campo e períodos temporais específicos — foram removidas do *dataframe*, evitando assim a redundância e reduzindo a dimensionalidade dos dados para o treinamento dos algoritmos.

Após a consolidação das variáveis de entrada, foram selecionados exclusivamente os registros de poços situados na Bacia de Campos, no estado do Rio de Janeiro. Essa filtragem espacial foi adotada para garantir que os modelos aprendam sobre um conjunto de poços com características físicas e operacionais próximas, evitando o treinamento com dados provenientes de contextos geológicos muito divergentes. Adicionalmente, a escolha dessa região justifica-se por representar o maior volume de observações disponíveis no *dataframe*.

Por fim, para obter o *dataframe* final utilizado pelos modelos, realizou-se o tratamento de anomalias e redundâncias, fase crítica para assegurar a veracidade e a integridade

dos dados antes do treinamento. Inicialmente, foram removidos todos os registros duplicados, garantindo que instâncias repetidas não gerassem um enviesamento indevido nos algoritmos. Na sequência, foram removidos registros com preenchimento inconsistente, considerando que registros com as variáveis de Vazão de Petróleo, Vazão de Água, Vazão de Gás e Lámina D'Água iguais a zero representam inconsistências. Para fazer a detecção dos *outliers* foi utilizada a biblioteca *IsolationForest* do Python, utilizando os valores númericos do *dataframe* para treinar o modelo, para que esse possa fazer a detecção dos valores discrepantes.

A exclusão, tanto de valores inconsistentes, quanto dos *outliers* visou assegurar que o treinamento ocorresse sobre um conjunto de dados representativo do comportamento operacional típico, melhorando assim a precisão e a confiabilidade das predições. Com a conclusão deste fluxo, o conjunto de dados apresentou-se devidamente limpo e enriquecido para a execução dos experimentos computacionais.

Após todos os procedimentos, o *dataframe* final apresentou as seguintes variáveis:

- **Vazão de Petróleo diária**: quantidade de Petróleo extraído por dia, medido em bbl.
- **Vazão de Água diária**: quantidade de Água extraída por dia, medido em bbl.
- **Vazão de Gás diária**: quantidade de Gás extraído por dia, medido em bbl.
- **Tempo de Produção**: número de horas no mês em que houve produção.
- **Grau API**: função especial da densidade relativa a 60°F/60°F, representada pela seguinte equação (Associação Brasileira de Normas Técnicas, 2013b):

$$^{\circ}\text{API} = \frac{141,5}{\text{densidade relativa } 60^{\circ}\text{F}/60^{\circ}\text{F}} - 131,5$$

- **Densidade Gás Liquefeito de Petróleo (GLP) Líquido**: razão entre a massa específica do GLP a uma dada temperatura e a massa específica da água a uma dada temperatura (Associação Brasileira de Normas Técnicas, 2013a).
- **Densidade GLP Gás**: relação entre a densidade absoluta do gás e a densidade absoluta do ar seco, na mesma pressão e temperatura (Associação Brasileira de Normas Técnicas, 2020).
- **Poder Calorífico Superior (PCS)**: quantidade de energia liberada na forma de calor, na combustão completa de uma quantidade definida de gás com o ar, à pressão constante e com todos os produtos de combustão retornando à temperatura e pressão iniciais dos reagentes, onde toda a água formada pela reação encontra-se em forma líquida (Associação Brasileira de Normas Técnicas, 2008).
- **Lâmina D'Água**: distância existente entre a superfície da água e o fundo do mar.

- **Idade**: Quantidade de dias em que o poço esteve ativo de o início da sua produção.
- **Preço de Referência**: preço de referência do Petróleo em um determinado mês.

Para a execução dos experimentos, o *dataframe* foi segmentado em duas componentes fundamentais: o conjunto de atributos (*features* ou *inputs*) e a variável alvo (*target* ou *output*). Enquanto a variável alvo representa a grandeza que o modelo deve estimar, as *features* constituem o vetor de variáveis independentes que fornecem os subsídios necessários para que o algoritmo identifique padrões de produção e realize as predições desejadas.

A partir dessa segmentação, os registros datados até o dia 31 de dezembro de 2023 foram selecionados como conjunto de **treino**, enquanto os dados posteriores foram designados para o conjunto de **teste**. Essa divisão temporal foi adotada com a finalidade de avaliar a capacidade dos modelos de predizer cenários futuros com base no histórico produtivo anterior. Dessa forma, o conjunto de treino foi destinado ao ajuste dos parâmetros internos dos modelos, enquanto o conjunto de teste foi reservado estritamente para mensurar a capacidade de generalização e a fidelidade preditiva das arquiteturas avaliadas.

Com os dados devidamente particionados, procedeu-se à padronização das *features* por meio da classe `StandardScaler`, ajustando os atributos para média zero e variância unitária. Essa etapa foi integrada diretamente ao processo de validação cruzada via `Pipeline` exclusivamente para os algoritmos sensíveis à escala das variáveis: Regressão Linear, Ridge, Lasso, KNN e SVR. Dessa forma, o ajuste do escalonador (*fit*) ocorreu estritamente sobre os subconjuntos internos de treino de cada *fold*, sendo apenas replicado (*transform*) nos conjuntos de validação e de teste. Essa abordagem mitiga o risco de *data leakage* (vazamento de dados) tanto na busca em grade quanto na avaliação final, assegurando que estatísticas dos dados futuros não influenciem o treinamento e refletindo um cenário operacional fidedigno. Por sua vez, os modelos baseados em árvores de decisão (*Random Forest*, *Gradient Boosting* e *LightGBM*) não precisaram desse ajuste, já que algoritmos baseados em árvores não são afetados pela escala das variáveis.

Concluída a etapa de pré-processamento, deu-se início ao treinamento e à avaliação dos modelos de *ML*. Os experimentos seguiram uma ordem planejada de avaliação: iniciou-se pelos modelos lineares para estabelecer uma *baseline* de desempenho, partindo-se em seguida para modelos baseados em árvores, modelos baseados em instâncias e margens, e finalizando com implementações avançadas de *boosting*.

Inicialmente, foram avaliados o modelo de Regressão Linear simples e suas extensões com regularização: Ridge e Lasso, verificando se o comportamento da vazão apresentava uma

natureza linear frente às variáveis operacionais. Na sequência, avaliaram-se os métodos baseados em árvores de decisão, empregando o Random Forest e o Gradient Boosting, visando capturar interações não lineares e mitigar ruídos operacionais. Em seguida, foram testados os algoritmos KNN e SVR, analisando o impacto do aprendizado baseado em vizinhança e margens de erro estruturais. Por fim, utilizou-se o LightGBM, explorando sua abordagem de particionamento acelerado e otimizado para o ajuste final das predições.

Para cada modelo, exceto o de Regressão Linear, foi utilizada a classe `GridSearchCV`, que realiza uma busca sobre um espaço de parâmetros previamente especificado. Este método opera em conjunto com a técnica de *k-fold cross-validation* (validação cruzada), dividindo o conjunto de treinamento em subpartes, que para o contexto desse trabalho foram utilizadas 3 subpartes, para garantir que a escolha dos melhores hiperparâmetros seja estatisticamente robusta e não dependente de uma única partição dos dados.

A aplicação desta técnica foi fundamental para ajustar parâmetros críticos, como o coeficiente de penalidade (α) nos modelos Lasso e Ridge, a profundidade máxima das árvores no Random Forest e XGBoost, e a quantidade de estimadores do LightGBM. Inicialmente, o `GridSearchCV` foi configurado para selecionar a combinação que maximizasse o coeficiente de determinação (R^2) no conjunto de validação, porém, após alguns testes, a ferramenta foi configurada para minimizar o RMSE, de modo a reduzir a magnitude dos erros. Essa mudança na estratégia do `GridSearch` foi feita sobre a justificativa de buscar melhorias de novas métricas, visto que o R^2 já estava atingindo valores satisfatórios. Tal abordagem assegura que a comparação final entre os modelos seja justa, uma vez que todos os algoritmos foram avaliados em suas configurações otimizadas.

Com todas as métricas estatísticas extraídas dos modelos, bem como o tempo de execução de todas as suas combinações utilizadas no `GridSearchCV`, tais informações foram registradas a fim de comparar e tirar conclusões sobre os algoritmos, de modo a tomar as melhores decisões levando em consideração o problema abordado no seguinte trabalho. As conclusões serão apresentadas no Capítulo 5. melhorar a descrição do Gurobi

A fim de complementar o estudo em questão, foi utilizada a ferramenta *Gurobi Machine Learning*, creio que o código não é aberto uma ferramenta de código aberto, desenvolvida na linguagem Python que permite os usuários utilizarem de modelos de *ML* treinados como restrições de um problema de PO, de modo a modelar as relações das variáveis (Gurobi, 2023). Para o problema em questão, foi utilizada como função objetivo a maximização da Vazão diária de Petróleo, nas restrições, os

valores de Vazão diária de Água, Vazão diária de Gás e o Tempo de Produção foram consideradas as variáveis de decisão do problema, enquanto os valores dos outros atributos foram fixados em um dos registros do *dataframe*, de modo a exemplificar e avaliar a utilização da ferramenta.

Após a conclusão dos experimentos, todas as métricas estatísticas de desempenho, juntamente com o custo computacional — mensurado pelo tempo de execução das combinações exaustivas do `GridSearchCV` — foram consolidadas para análise. Esse conjunto de dados foi fundamental para fundamentar uma análise comparativa rigorosa entre os algoritmos, permitindo avaliar o equilíbrio entre precisão preditiva e eficiência computacional. Dessa forma, a seleção do modelo ideal foi pautada por critérios técnicos alinhados às necessidades de emulação de sistemas de produção de poços marítimos. As análises detalhadas e as discussões sobre o desempenho de cada arquitetura serão apresentadas no Capítulo 5.

5 EXPERIMENTOS COMPUTACIONAIS

Este capítulo apresenta a consolidação e a discussão ~~aprofundada~~ dos resultados obtidos através da otimização e avaliação de diversas famílias de algoritmos de Machine Learning. O objetivo primário foi identificar o modelo com o melhor balanço entre a **precisão preditiva** (maior R^2 de Teste e menores RMSE e MAE de Teste) e a **capacidade de generalização** (ΔR^2 minimizado) para a previsão da Vazão Diária de Petróleo.

Todos os modelos foram treinados utilizando o *dataframe*, que foi gerado a partir dos procedimentos explicados no Capítulo 4. A média de produção do *dataframe* final foi utilizada como *baseline* de comparação dos modelos, com essa estatística tendo o valor de **2481.8066** bbl/dia, e a partir do qual o RMSE é percentualmente avaliado.

5.1 Métricas Consolidadas de Desempenho

A Tabela 1 resume as métricas de desempenho de precisão (R^2 e RMSE), generalização (ΔR^2) e eficiência computacional (*Tempo de Treinamento em segundos*) para os oito modelos otimizados.

Tabela 1 – Métricas Consolidadas de Desempenho dos Modelos

Modelo	R^2 Treino	R^2 **Teste**	RMSE Teste	MAE Teste	ΔR^2	RMSE Teste / Média	MAE Teste / Média	Tempo (segundos)
Regressão Linear	0.6127	0.405	1477.0898	862.5887	0.2077	59.52%	34.76%	0.0248
Ridge	0.6127	0.405	1477.093	862.5752	0.2077	59.52%	34.76%	0.0046
Lasso	0.6118	0.4032	1479.3423	860.7121	0.2086	59.61%	34.68%	3.1099
Random Forest	0.9924	0.8145	824.0745	543.4489	0.1779	33.2%	21.9%	28.6838
XGBoost	0.998	0.8347	778.5747	519.5239	0.1633	31.37%	20.93%	5.4837
K-NN	1.0000	0.6815	1080.7433	679.2965	0.3185	43.55%	27.37%	0.0179
SVR	0.8494	0.7611	935.838	632.4903	0.0883	37.71%	25.49%	2.986
LightGBM	0.9967	0.8267	797.1118	540.7035	0.17	32.12%	21.79%	1.5829

Descrever cada coluna da tabela 1

5.2 Análise e Discussão dos Resultados

A análise dos resultados se divide em três pontos principais: a performance dos modelos lineares, o salto de precisão dos modelos não-lineares, e a comparação de *trade-offs* entre os modelos de maior performance.

5.2.1 Performance dos Modelos Lineares (Base)

Os modelos de Regressão Linear, Ridge e Lasso apresentaram um R^2 de Teste de aproximadamente **0.40**. Este resultado indica que a abordagem linear consegue explicar apenas 40% da variabilidade da vazão de petróleo. O erro associado é extremamente alto, com o valor RMSE estando acima de **1477** bbl/dia nos 3 modelos, o que representa mais **59**% da produção média. Quando é observada a métrica de MAE, a magitude dos erros foram inferiores, apresentando valores entre 860.7121 e 862.5887 bbl/dia, o que representa de 34.68% a 34.76% da produção média. Porém, é importante ressaltar que a métrica RMSE é mais sensível a grandes erros. Por fim, ao analisar o ΔR^2 dos modelos lineares, essa métrica apresentou valores baixos, entre 0.2077 e 0.2086, o que, aliado ao baixo R^2 de treino, indica que os modelos não decoraram os dados de treino.

A partir do desempenho dos modelos lineares, confirma-se que a relação entre as variáveis operacionais e a Vazão de Petróleo Diária é intrinsecamente não linear, evidenciando que a rigidez estrutural dessas formulações é insuficiente para capturar a complexidade física do problema.

5.2.2 O Salto de Precisão dos Modelos Não-Lineares

A migração para algoritmos capazes de mapear relações não-lineares resultou em um aumento considerável no poder preditivo:

- O R^2 de Teste subiu de 0.40 para mais de **0.81** nos melhores modelos.
- O RMSE foi reduzido para valores entre **778** e **1081** bbl/dia.
- O MAE foi reduzido para valores entre **519** e **680** bbl/dia.

Os modelos **XGboost**, **LightGBM** e **Random Forest** se destacaram, alcançando os melhores resultados de R^2 de Teste, todos com valores superiores a 0.81, uma baixa magnitude de erros, com RMSE estando entre 778 e 825 bbl/dia e MAE estando entre 519 e 544 bbl/dia, e uma boa generalização, com ΔR^2 entre 0.16 e 0.18. Dadas essas métricas, tais modelos serão considerados de alta performance para esse problema.

5.2.3 Análise do Trade-Off: Precisão, Generalização e Tempo

A escolha do modelo final é determinada pelo balanceamento entre precisão, generalização e eficiência computacional, com essa última sendo medida pelo tempo de treinamento do

modelo.

- **Generalização (ΔR^2):** O SVR apresentou a melhor generalização absoluta ($\Delta R^2 = 0.0883$), mas sua precisão final ($R^2 = 0.7611$) foi baixa em relação aos melhores algoritmos. Entre os modelos de alta performance, o **XGBoost** apresentou a menor perda de generalização ($\Delta R^2 = 0.1633$), indicando que sua estrutura é mais robusta e menos suscetível ao *overfitting* do que o LightGBM e o Random Forest.
- **Eficiência (Tempo de Treinamento):** O KNN apresentou valores satisfatórios em relação ao tempo de treinamento, sendo inferior a **1** segundo, sendo o menor dentre os modelos não lineares, porém apresentou uma baixa precisão ($R^2 = 0.6815$), sendo a menor dentre os outros modelos de sua mesma famíla. Quanto aos modelos de alta performance, o **LightGBM** se mostrou o mais eficiente, treinando em aproximadamente **1.58** segundos. Esse baixo tempo de treinamento representa um valor excelente dada sua alta capacidade preditiva ($R^2 = 0.8267$).

Dada a proximidade dos melhores modelos em relação às métricas de erro, levando em consideração a baixa amplitude do RMSE e do MAE, de **45.4998** e **23.925** respectivamente, tais estatíticas não foram tão significantes para a escolha entre esses modelos.

5.3 Definição do Modelo Final

Com base na análise das métricas, os modelos **XGBoost** e **LightGBM** se mostraram os principais candidatos para modelos finais.

- XGBoost atingiu o melhor R^2 de Teste, com o valor de **0.8347**, porém, ainda próximo do LightGBM, que alcançou um R^2 de Teste de **0.8267**.
- O RMSE dos modelos também foram próximos, de **778.5747** e **797.1118** bbl/dia, para o XGBoost e o LightGBM respectivamente, o que representa uma diferença de apenas 18.5371 bbl/dia. Algo similar ocorre em relação ao MAE, onde a diferença entre as métricas dos modelos foi de apenas 21.1796 bbl/dia.
- Ambos os modelos atingiram generalização próximas, com ΔR^2 de **0.1633** para o XGBoost e **0.17** para o LightGBM.

A maior diferença entre os 2 modelos está no tempo de treinamento, de modo que o **LightGBM** apresentou um tempo de execução menor em relação ao **XGBoost**, havendo uma diferença de aproximadamente 4 segundos no treinamento dos modelos, o que justifica a escolha do modelo mais eficiente, principalmente no caso de haver a necessidade de um retreinamento

Tabela 2 – Parâmetros do Problema

Nome do Parâmetro	Valor
Grau API	26.8
Densidade GLP Gás	2.007620
Densidade GLP Líquido	528.9763
PCS	42550.658
Idade	1353
Lâmina D'Água	941
Distância do Vizinho 1	1.2
Distância do Vizinho 2	2.47
Distância do Vizinho 3	2.64
Poços no Raio de 2 km	1

frequente. Desse modo, o modelo **LightGBM** se mostrou aquele que melhor se adaptou ao problema abordado nesse trabalho.

Todos os experimentos com os modelos foram realizados em um computador com as seguintes configurações:

- **Processador:** AMD Ryzen 5 5600GT com 3.60 GHz.
- **Memória:** 16 GB de RAM.
- **Placa de Vídeo:** NVIDIA GeForce RTX 3050 com 8 GB de VRAM.
- **Sistema Operacional:** Windows 11 Home
- **Linguagem de Programação:** Python 3.14.2

5.4 Testes com o Gurobi

Para avaliar o desempenho dos modelos no ambiente de otimização matemática com o *solver* Gurobi, foram formuladas instâncias do problema que utilizaram os três modelos de *ML* que obtiveram o melhor desempenho preditivo na Seção 5.1:

- XGBoost
- LightGBM
- Random Forest

A Tabela 2 sintetiza os parâmetros constantes atribuídos ao problema. Esses valores foram obtidos a partir de um registro aleatório extraído do conjunto de treino, mantendo a coerência geológica e operacional conforme detalhado na Seção 2.1.

A Tabela 3 descreve os domínios e os limites operacionais impostos às variáveis de decisão. Para as vazões de água e gás, assim como para o tempo de produção, o limite inferior correspondeu ao valor mínimo histórico verificado na base de treino, enquanto o limite

Tabela 3 – Limites das Variáveis

Variável	Limite Inferior	Limite Superior
Vazão de Água	0.0008	∞
Vazão de Gás	0.0002	∞
Tempo de Produção	1.0	∞
Preço de referência	1343.1815	2239.3258

Tabela 4 – Soluções das Variáveis

Variável	Random Forest	XGBoost	LightGBM
Vazão de Água	41.86	45.67	53.88
Vazão de Gás	178.92	226.9	230.55
Tempo de Produção	718	717	718.5
Preço de Referência	2111.13	2239.33	2229.36
Vazão de Petróleo	11703.69	11552.55	11916.06

superior foi determinado como infinito a fim de não limitar a decisão do *solver* às informações da distribuição histórica com o qual o modelo foi treinado. Em relação ao Preço de Referência, fixaram-se como limites inferior e superior o primeiro e o terceiro quartis da distribuição histórica, respectivamente.

Por fim, a Tabela 4 consolida as soluções ótimas encontradas pelo Gurobi ao utilizar cada um dos três modelos preditivos. Sob idênticas condições de restrições e parâmetros, a formulação que utilizou o modelo **LightGBM** alcançou o maior valor na função objetivo — maximização da vazão diária de petróleo —, atingindo 11.916,06 bbl/dia e superando as soluções obtidas via *Random Forest* e XGBoost. Esse resultado evidencia a capacidade do modelo em determinar fronteiras de partição mais favoráveis à busca do solucionador exato, validando a sua escolha como o modelo final da pesquisa.

Todos os experimentos de otimização foram executados em um ambiente computacional com as seguintes especificações:

- **Processador:** Intel® Core™ 7 150U × 12;
- **Memória:** 32 GB de RAM;
- ***Solver* Matemático:** Gurobipy 13.0.2 e Gurobi-machinelearning 1.7.0;
- **Sistema Operacional:** Ubuntu Linux 24.04;
- **Linguagem de Programação:** Python 3.12.3.

Ainda a melhorar!

6 CONCLUSÃO

Este trabalho conseguiu cumprir seu objetivo de desenvolver um modelo de *ML* que se adeque aos dados de produção de poços de petróleo marítimo a fim de otimizar sua produção. O problema em questão, após análises comparativas das métricas dos modelos, demonstrou possuir uma natureza não linear, dado que modelos mais simples, que consideram o problema como linear, não conseguiram se adequar aos dados, explicando apenas cerca de 40.5% da variabilidade dos dados com RMSE e MAE elevados, com valores que representam 59.52% e 34.76% da média de produção diária, respectivamente.

Dentre todos os modelos, o **LightGBM** foi aquele que se destacou por conseguir se adequar os dados, conseguindo predizer bem os valores de produção de petróleo diário, com uma taxa de acerto de 82.67%, com um RMSE em torno de 32.12% e um MAE com valor de 21.79%, em relação à média de produção diária dos poços, e apresentando um um bom tempo para o treinamento com os dados utilizados, levando 1.58 segundo para a realização do treinamento no modelo com os melhores hiperparâmetros, determinados pelo `GridSearchCV`.

De modo a complementar os testes realizados nesse trabalho, foi utilizado o *solver* Gurobi, a fim de avaliar o desempenho dos 3 modelos que tiveram as melhores métricas, utilizando os modelos treinados como uma das restrições de um problema de PO. Após as execuções dos testes com o *solver*, o **LightGBM** foi aquele que conseguiu indicar os valores das variáveis que conseguem maximizar a Vazão Diária de Petróleo.

REFERÊNCIAS

ASHER, M. J.; CROKE, B. F. W.; JAKEMAN, A. J.; PEETERS, L. J. M. A review of surrogate models and their application to groundwater modeling. **Water Resources Research**, v. 51, n. 8, p. 5957–5973, 2015.

ASNICAR, F.; THOMAS, A. M.; PASSERINI, A.; WALDRON, L.; SEGATA, N. Machine learning for microbiologists. **Nature Reviews Microbiology**, v. 22, n. 4, p. 191–205, Apr 2024.

Associação Brasileira de Normas Técnicas. **ABNT NBR 15213: Gás natural e outros combustíveis gasosos - Cálculo do poder calorífico, densidade absoluta, densidade relativa e índice de Wobbe a partir da composição.** Rio de Janeiro, 2008.

Associação Brasileira de Normas Técnicas. **ABNT NBR 14065: Destilados de petróleo e óleos viscosos — Determinação da massa específica e da densidade relativa pelo densímetro digital.** Rio de Janeiro, 2013.

Associação Brasileira de Normas Técnicas. **ABNT NBR 7148: Petróleo e produtos de petróleo — Determinação da massa específica, densidade relativa e API — Método do densímetro**. Rio de Janeiro, 2013.

Associação Brasileira de Normas Técnicas. **ABNT NBR 15358: Rede de distribuição interna para gás combustível em instalações de uso não residencial de até 400 kPa — Projeto e execução.** Rio de Janeiro, 2020.

BASAK, D.; PAL, S.; PATRANABIS, D. Support vector regression. **Neural Information Processing – Letters and Reviews**, v. 11, 11 2007.

BIAU, G. Analysis of a random forests model. **Journal of Machine Learning Research**, v. 13, p. 1063–1095, 2012.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, p. 5–32, 10 2001.

CHAKRABARTI, S.; HALKYARD, J.; CAPANOGLU, C. Chapter 1 - historical development of offshore structures. In: CHAKRABARTI, S. K. (Ed.). **Handbook of Offshore Engineering**. London: Elsevier, 2005. p. 1–38. ISBN 978-0-08-044381-2. Disponível em: <https://www.sciencedirect.com/science/article/pii/B9780080443812500047>.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. **CoRR**, abs/1603.02754, 2016. Disponível em: <https://doi.org/10.48550/arXiv.1603.02754>.

FRIEDMAN, J. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, p. 1189–1232, 10 2001.

GAO, S.; LI, H.; NIE, S.; AI, Y.; LUO, H.; LI, Y. Design and numerical simulation study of a novel aicd for water control and gas production in gas wells. **ACS Omega**, American Chemical Society, v. 8, p. 39052–39066, 2023.

Gurobi. **Embed your trained machine learning models directly into Gurobi.** 2023. Disponível em: <https://www.gurobi.com/misc/lp/all/gurobi-machine-learning>. Acesso em: 17 aug. 2026.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer Science & Business Media, 2009. Disponível em: <https://web.stanford.edu/~hastie/ElemStatLearn/>.

HILLIER, F. S.; LIEBERMAN, G. J. **Introdução à pesquisa operacional**. [S.l.]: McGraw Hill Brasil, 2013.

IEA. **World Energy Outlook 2025**. Paris, 2025. Disponível em: <https://www.iea.org/reports/world-energy-outlook-2025>.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning: with Applications in R**. [S.l.]: Springer, 2013.

KAVLAKOGLU, E. **O que é o algoritmo k-nearest neighbors (KNN)?** 2021. Disponível em: <https://www.ibm.com/br-pt/think/topics/knn>.

KE, G.; MENG, Q.; FINLEY, T.; WANG, T.; CHEN, W.; MA, W.; YE, Q.; LIU, T.-Y. Lightgbm: A highly efficient gradient boosting decision tree. Curran Associates, Inc., v. 30, 2017. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>.

LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: IEEE. **2008 eighth ieee international conference on data mining**. [S.l.], 2008. p. 413–422.

LOH, W.-Y. Fifty years of classification and regression trees. **International Statistical Review**, v. 82, p. 329–348, 06 2014.

MARTINS, S. S. S.; SILVA, M. P.; AZEVEDO, M. O.; SILVA, V. P. Produção de Petróleo e Impactos Ambientais: Algumas Considerações. **HOLOS**, v. 6, n. 1807-1600, p. 54–76, 2015. ISSN 1807-1600.

MME, M. **Como uma plataforma tira petróleo do fundo do mar?** 2023. Disponível em: <https://www.gov.br/mme/pt-br/assuntos/noticias/como-uma-plataforma-tira-petroleo-do-fundo-do-mar>. Acesso em: 05 nov. 2025.

MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. **Sistemas inteligentes - Fundamentos e aplicações**, v. 1, n. 1, p. 32, 2003.

MORAIS, J. M. d. Determinantes das Tecnologias de Produção de Petróleo no Mar. **Radar - Tecnologia, Produção e Comércio Exterior**, IPEA, n. 17, p. 27–34, 2011. Disponível em: <http://repositorio.ipea.gov.br/handle/11058/3460>.

MüLLER, K.-R.; MIKA, S.; RäTSCH, G.; TSUDA, K.; SCHöLKOPF, B. An introduction to kernel-based learning algorithms. **IEEE Transactions on Neural Networks**, v. 12, p. 181–201, 02 2001.

PORTELLA, F.; BUCHACA, D.; RODRIGUES, J. R.; BERRAL, J. L. TunaOil: A tuning algorithm strategy for reservoir simulation workloads. **Journal of Computational Science**, v. 63, p. 101811, 2022. ISSN 1877-7503.

RIDZUAN, F.; Wan Zainon, W. M. N. A review on data cleansing methods for big data. **Procedia Computer Science**, v. 161, p. 731–738, 2019. ISSN 1877-0509. The Fifth Information Systems International Conference, 23-24 July 2019, Surabaya, Indonesia.

SIKANYIKA, E. W.; WU, Z.; MBAROUK, M. S.; MAFIMBA, A. M.; ELBALOULA, H. A.; JIANG, S. Numerical simulation of the oil production performance of different well patterns with water injection. **Energies**, MDPI, v. 16, p. 91, 2023.

TSUKADA, R. I.; YAMAMOTO, M.; MOROOKA, C. K. Análise de Operação da Instalação de Risers e Descida de BOP em Sondas Flutuantes de Perfuração. In: **PDPETRO - Congresso Brasileiro de Pesquisa e Desenvolvimento em Petróleo e Gás**. Campinas, SP: [s.n.], 2007. p. 2.4.308–1–2.4.308–9.

VAPNIK, V. N. **The Nature of Statistical Learning Theory**. New York, NY: Springer-Verlag, 1995. ISBN 978-0-387-98780-4.

WU, G.; MA, Y.; CAO, Y.; ZHANG, A.; LIU, W.; WANG, J.; YANG, X. Optimization of well patterns in offshore low-permeability thin interbedded reservoirs: A numerical simulation study in the bozhong oilfield, china. **Energies**, MDPI, v. 18, p. 285, 2025.

ŠTUREK, D.; LAZAROVA-MOLNAR, S. Surrogate modeling: Review and opportunities for expert knowledge integration. **Procedia Computer Science**, Elsevier B.V., v. 257, p. 826–833, 2025.