UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE CIÊNCIAS

DEPARTAMENTO DE ESTATÍSTICA E MATEMÁTICA APLICADA

PROGRAMA DE PÓS-GRADUAÇÃO EM MODELAGEM E MÉTODOS QUANTITATIVOS

MESTRADO ACADÊMICO EM MODELAGEM E MÉTODOS QUANTITATIVOS

ICARO DE SOUSA RODRIGUES

USO DE MODELOS DE APRENDIZAGEM DE MÁQUINA PARA OTIMIZAÇÃO DE SIMULADORES DE POÇOS DE PETRÓLEO MARÍTIMO

FORTALEZA

2026

ICARO DE SOUSA RODRIGUES

USO DE MODELOS DE APRENDIZAGEM DE MÁQUINA PARA OTIMIZAÇÃO DE SIMULADORES DE POÇOS DE PETRÓLEO MARÍTIMO

Proposta de qualificacao apresentada ao Curso de Mestrado Acadêmico em Modelagem e Métodos Quantitativos da Universidade Federal do Ceará (UFC) como requisito parcial para a defesa de dissertação.
Orientador: Prof. Dr. Jesus Ossian da Cunha Silva

FORTALEZA

2026

ICARO DE SOUSA RODRIGUES

USO DE MODELOS DE APRENDIZAGEM DE MÁQUINA PARA OTIMIZAÇÃO DE SIMULADORES DE POÇOS DE PETRÓLEO MARÍTIMO

Proposta de qualificacao apresentada ao Curso de Mestrado Acadêmico em Modelagem e Métodos Quantitativos da Universidade Federal do Ceará (UFC) como requisito parcial para a defesa de dissertação.

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. Jesus Ossian da Cunha Silva (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Michael Ferreira de Souza
Universidade Federal do Ceará (UFC)

Prof. Dr. Luís Fabrício de Freitas Souza
Universidade Federal do Cariri (UFCA)

RESUMO

Esta proposta de qualificação de mestrado apresenta a aplicação de modelos de Aprendizagem de Máquina para a otimização de simuladores de poços de petróleo marítimo. Tais modelos utilizam-se de dados e, por meio de treinamentos específicos, tornam-se capazes de mimetizar o comportamento de simuladores físicos com precisão aceitável e baixo custo computacional. A metodologia abrange a extração de dados reais do sistema de Consulta de Dados Públicos (CDP) da Petrobras, referente ao período de janeiro de 2023 a agosto de 2025. O fluxo de trabalho incluiu um processo rigoroso de limpeza de dados (*Data Cleansing*), engenharia de atributos e transformações matemáticas para estabilização de variância. Foram realizados experimentos computacionais comparando 8 (oito) algoritmos de Aprendizagem de Máquina, submetidos à otimização de hiperparâmetros via *GridSearchCV*. Os resultados demonstram que o modelo baseado em *Random Forest Regressor* obteve o melhor desempenho, alcançando um coeficiente de determinação (R^2) de 0,9272 e reduzindo o erro médio (RMSE) em mais de 58% comparado aos modelos lineares. Como etapas subsequentes até a defesa da dissertação, pretende-se realizar o estudo e implementação de modelos de *Deep Learning* e Redes Neurais Informadas pela Física (*PINN*), além da integração do modelo preditivo final à biblioteca de otimização `gurobipy` para a obtenção de *setpoints* operacionais otimizados. Conclui-se que a abordagem não linear é essencial para capturar as complexas interações do reservatório, validando o uso de modelos *surrogate* como ferramentas eficientes para o gerenciamento de produção *offshore*.

Palavras-chave: Aprendizagem de Máquina. Modelos Surrogate. Otimização. Poços de Petróleo.

ABSTRACT

This Master's qualification proposal presents the application of Machine Learning models for the optimization of offshore oil well simulators. These data-driven models, through specific training, are capable of mimicking the behavior of physical simulators with acceptable precision and low computational cost. The methodology covers the extraction of real-world data from Petrobras' Public Data Consultation (CDP) system, spanning from January 2023 to August 2025. The workflow included a rigorous data cleansing process, feature engineering, and mathematical transformations for variance stabilization. Computational experiments were conducted comparing 8 (eight) Machine Learning algorithms, subjected to hyperparameter optimization via *GridSearchCV*. Results demonstrate that the *Random Forest Regressor*-based model achieved the best performance, reaching a coefficient of determination (R^2) of 0.9272 and reducing the root mean squared error (RMSE) by more than 58% compared to linear models. As subsequent steps leading up to the thesis defense, it is intended to study and implement Deep Learning and Physics-Informed Neural Networks (PINN) models, as well as integrate the final predictive model with the `gurobipy` optimization library to obtain optimized operational setpoints. It is concluded that the non-linear approach is essential for capturing complex reservoir interactions, validating the use of surrogate models as efficient tools for offshore production management.

Keywords: Machine Learning. Surrogate Models. Optimization. Oil Wells.

LISTA DE FIGURAS

LISTA DE TABELAS

Tabela 1 – Métricas Consolidadas de Desempenho dos Modelos 30

LISTA DE ABREVIATURAS E SIGLAS

FPSO	*Floating Production Storage and Offloading*/Unidade Flutuante de Armazenamento e Transferência
ML	*Machine Learning*/Aprendizagem de Máquina
BOP	*Blowout Preventer*/Dispositivo antirruptura
BSW	*Basic Sediment and Water*/Sedimentos Básicos e Água
CDP	Consulta de Dados Públicos
CFD	*Computational Fluid Dynamics*/Dinâmica dos Fluidos Computacional
IA	Inteligência Artificial
IQR	Intervalo Interquartil
KNN	*K-Nearest Neighbors*
MAE	*Mean Absolute Error*/Erro Absoluto Médio
MLP	*Multilayer Perceptron*
MSE	*Mean Squared Error*/Erro Quadrático Médio
OLS	*Ordinary Least Squares*/Mínimos Quadrados Ordinários
PINN	*Physics-Informed Neural Network*/Rede Neural Informada pela Física
PO	Pesquisa Operacional
RMSE	*Root Mean Squared Error*/Raiz do Erro Quadrático Médio
RSS	*Residual Sum of Squares*/Soma dos Quadrados dos Resíduos
SVR	*Suport Vector Regression*
TSS	*Total Sum of Squares*
UQ	*Uncertainty Quantification*/Quantificação de Incerteza

LISTA DE SÍMBOLOS

bbl/dia	Barril por dia

SUMÁRIO

1 INTRODUÇÃO 10
2 PROBLEMA 13
2.1 Problema Linear 13
2.2 Problema Não Linear 14
2.3 Métricas 15
3 FUNDAMENTAÇÃO TEÓRICA 17
3.1 Fundamentos de Pesquisa Operacional (PO) 17
3.2 Fundamentos de Limpeza de Dados para Modelagem 18
3.3 Fundamentos de *Machine Learning*/Aprendizagem de Máquina (*ML*) . . 19
3.3.1 Generalização e Overfitting 20
3.4 Modelos *Surrogate* na Otimização de Sistemas de Produção 20
3.5 Formalização Matemática dos Modelos de Aprendizado de Máquina . . 21
3.5.1 Regressores Lineares e Regularização 21
3.5.2 Modelos de Vizinhança e Suporte (KNN e SVR) 22
3.5.3 Modelos Baseados em Árvores e Ensembles (Random Forest e XGBoost) . 22
3.5.4 Redes Neurais Artificiais (MLP) 22
4 PROPOSTA E METODOLOGIA 24
5 EXPERIMENTOS COMPUTACIONAIS 30
5.1 Métricas Consolidadas de Desempenho 30
5.2 Análise e Discussão dos Resultados 30
5.2.1 Performance dos Modelos Lineares (Base) 31
5.2.2 O Salto de Precisão dos Modelos Não-Lineares 31
5.2.3 Análise do Trade-Off: Precisão, Generalização e Tempo 31
5.3 Definição do Modelo Final 32
6 CONCLUSÃO 33
7 CRONOGRAMA 34
REFERÊNCIAS 35

1 INTRODUÇÃO

A extração de petróleo em ambiente marítimo constitui uma das atividades de engenharia de maior complexidade e investimento global, sendo essencial para a matriz energética mundial. Os esforços em Pesquisa e Desenvolvimento (P&D) envolvidos nessas operações são cruciais para superar os desafios tecnológicos, especialmente em águas profundas (MORAIS, 2011). Esse processo, que se inicia com campanhas exploratórias e culmina na produção efetiva, é realizado a partir de estruturas especializadas, as plataformas de petróleo, e exige um rigoroso licenciamento ambiental em todas as suas fases, dada a necessidade de compreender e mitigar os impactos ambientais gerados pela atividade (MARTINS *et al.*, 2015).

De acordo com (MME, 2023), a etapa de desenvolvimento do campo de petróleo e gás natural envolve a perfuração de poços e a instalação de um complexo sistema submarino, havendo diversas técnicas para a construção e montagem de uma plataforma, sendo um dos fatores determinantes a profundidade do campo de petróleo e gás. Em profundidades de até 400 metros, o tipo de plataforma é considerada de águas rasas, e sua estrutura pode ficar sobre torres de concreto e aço, capazes de aguentar todas as intempéries do tempo e mar revolto. Já no caso de uma maior profundidade, fazendo com que a plataforma esteja parcialmente submersa, as plataformas são do tipo semissubmersíveis, tendo uma maior estabilidade, visto que esse são instalados pontos de ancoragem para evitar que as instalações fiquem à deriva no oceano. Por fim, existe a chamada *Floating Production Storage and Offloading*/Unidade Flutuante de Armazenamento e Transferência (*FPSO*), que são navios com capacidade de processar, armazenar e transferir petróleo e gás natural a outros navios.

Com a perfuração do poço, feita por meio do uso de uma broca com dente de aço, é necessária a instalação do equipamento de segurança chamado *Blowout Preventer*/Dispositivo antirruptura (BOP). Esse dispositivo consiste em um sistema hidráulico ou eletro-hidráulico fundamental para vedar o poço e prevenir acidentes de vazamento sob alta pressão. Para conectar o BOP na cabeça do poço à unidade de perfuração na superfície, utiliza-se do *drilling riser*, que é uma coluna tubular essencial que atua como um conduto de retorno dos fluidos de perfuração e guia para as ferramentas. Há também a chamada Árvore de Natal Molhada, um conjunto de válvulas que gerencia o fluxo de produção. A operação de instalação desses equipamentos críticos, como o lançamento e descida dos *risers* e o assentamento do BOP no solo marítimo, representa um dos maiores desafios logísticos e de segurança em sistemas de perfuração marítima (TSUKADA *et al.*, 2007). O produto final (petróleo e gás) é escoado por

dutos ou navios petroleiros.

Quanto à simulação numérica de reservatórios, este é um método amplamente reconhecido e eficaz para a exploração de questões complexas e o estudo do comportamento de fluxo em condições reais de reservatório (SIKANYIKA *et al.*, 2023). Devido ao alto custo e aos desafios operacionais, especialmente em campos *offshore* e reservatórios de baixa permeabilidade, a indústria busca sempre melhorar a produção, com menos poços, tornando a precisão e a eficiência da modelagem críticas (WU *et al.*, 2025).

A modelagem de reservatórios é governada por equações diferenciais parciais que descrevem o fluxo de fluidos (óleo, gás, água) em meios porosos, como as equações do modelo *Black-Oil* (SIKANYIKA *et al.*, 2023). Além da complexidade do reservatório, a simulação detalhada de componentes do poço também exige a solução de equações de alta complexidade. Por exemplo, a otimização de dispositivos de controle de fluxo requer a aplicação de *Computational Fluid Dynamics*/Dinâmica dos Fluidos Computacional (CFD) para resolver as equações de continuidade e de momento para escoamento turbulento, muitas vezes empregando modelos como o $k-\varepsilon$ (GAO *et al.*, 2023).

O desafio central reside no custo computacional elevado e no tempo de execução desses modelos de alta fidelidade. A simulação de um cenário único em um campo complexo pode consumir horas ou até dias. Essa lentidão se torna um gargalo insustentável em tarefas cruciais de gerenciamento e otimização, tais como:

- ***Uncertainty Quantification*/Quantificação de Incerteza (UQ)**: A avaliação robusta da incerteza dos parâmetros do reservatório (porosidade, permeabilidade, etc.) exige a execução de milhares de simulações (e.g., Monte Carlo) (WU *et al.*, 2025).
- **Otimização de Produção e Otimização Econômica**: A busca pelo posicionamento ideal de poços ou pela maximização do Valor Presente Líquido (VPL) envolve a iteração contínua sobre diversos parâmetros (espaçamento, fraturamento, padrões de injeção), necessitando de um modelo rápido para avaliar cada tentativa (WU *et al.*, 2025).
- **Estudo de Cenários**: A comparação entre diferentes estratégias, como poços horizontais versus verticais, com injeção de água, embora factível, é limitada pelo tempo disponível para rodar um grande número de iterações em busca de maior eficiência de recuperação (SIKANYIKA *et al.*, 2023).

A estrutura deste trabalho está organizada em capítulos que detalham o problema abordado, o embasamento teórico, os métodos utilizados nos experimentos e resultados obtidos.

A organização segue a seguinte ordem:

- **Capítulo 2:** Define formalmente o problema de previsão de vazão, estabelecendo as modelagens matemáticas para as abordagens linear e não linear, além de descrever as métricas estatísticas utilizadas para a otimização dos modelos.
- **Capítulo 3:** Reúne a fundamentação teórica necessária para a compreensão dos conceitos de extração de petróleo *offshore*, modelagem *surrogate* e os princípios matemáticos dos algoritmos de Aprendizado de Máquina selecionados.
- **Capítulo 4:** Detalha o fluxo metodológico, abrangendo a extração de dados no sistema de Consulta de Dados Públicos (CDP), o processo rigoroso de limpeza de dados (*Data Cleansing*), a engenharia de atributos e a configuração dos experimentos computacionais.
- **Capítulo 5:** Expõe os resultados alcançados, apresentando a comparação de desempenho entre os modelos lineares, de conjunto e redes neurais, baseando-se nas métricas de erro estatístico e custo computacional.
- **Capítulo 6:** Sintetiza as principais conclusões obtidas, discute as limitações da pesquisa e propõe sugestões de trabalhos futuros para o aprimoramento da modelagem preditiva em sistemas de produção.

2 PROBLEMA

A otimização da produção de petróleo em poços é uma tarefa crítica de engenharia, cuja eficiência está diretamente ligada à acurácia da previsão da Vazão Diária de Petróleo ($\hat{y}$) em função das variáveis operacionais e de reservatório (X). As complexas interações entre estas variáveis frequentemente dificultam a obtenção de estimativas precisas por métodos tradicionais, que falham em mapear a função $f(X)$ de forma satisfatória. Tais iterações entre as variáveis, pode classificar o problema quanto à sua linearidade, se este será **linear** ou **não-linear**, e dada a grande quantidade de variáveis, é muito difícil classificar o problema apenas com a observação dos dados. Sendo assim, o problema abordado será modelado de ambas as formas e serão utilizadas as métricas dos modelos de *ML*, apresentados no Capítulo 5, para determinar a natureza do problema, levando em consideração que foram utilizados modelos diferentes, onde alguns assumem o problema como linear e outros como não-linear, o que será melhor detalhado no Capítulo 4.

Abaixo serão apresentados os 2(dois) tipos de modelagem do problema em questão, além do problema de otimização das métricas.

2.1 Problema Linear

Esta modelagem representa o problema como linear, onde se busca o vetor de coeficientes β que minimiza o erro quadrático (*Residual Sum of Squares*/Soma dos Quadrados dos Resíduos (RSS)), assumindo uma relação aditiva. Abaixo é apresentada a formulação linear para o problema:

$$\min_{\beta \in \mathbb{R}^{p+1}} \quad J(\beta) = \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} \right) \right)^2 + \lambda \cdot R(\beta) \tag{2.1}$$

$$\text{s.t.} \quad \beta_j \in \mathbb{R}, \quad \forall j \in \{1,2,\ldots,p\} \tag{2.2}$$

$$y_i \in \mathbb{R}_+, \quad \forall i \in \{1,2,\ldots,n\} \tag{2.3}$$

$$x_{ij} \in [L_{min}, L_{max}], \quad \forall i \in \{1,2,\ldots,n\}, \forall j \in \{1,2,\ldots,p\} \tag{2.4}$$

Na formulação apresentada, a equação (2.1) define a função objetivo, composta pela Soma dos Quadrados dos Resíduos (RSS) e pelo termo de penalidade $\lambda \cdot R(\beta)$, utilizado para regularização. As variáveis de decisão são dadas pelo vetor β, que contém o intercepto (β_0) e os pesos associados a cada atributo do poço.

Para a formalização do modelo, definem-se os domínios das variáveis envolvidas:

- **Vetor de Saída (y_i):** Representa a Vazão Diária de Petróleo registrada para a i-ésima observação, com domínio definido por $y_i \in \mathbb{R}_+$, definido na Equação 2.3, respeitando a impossibilidade física de produção negativa.
- **Matriz de Atributos (x_{ij}):** Representa o valor da j-ésima característica na i-ésima instância. O domínio de cada atributo é restrito ao conjunto dos números reais dentro de limites operacionais e físicos específicos, tal que $x_{ij} \in [L_{\min,j}, L_{\max,j}]$, definido na Equação 2.4.

A equação (2.2) estabelece que os coeficientes pertencem ao espaço dos números reais, garantindo a flexibilidade necessária para que o modelo identifique a influência de cada variável operacional, como o Grau API e a Idade, na produção final.

2.2 Problema Não Linear

Esta modelagem representa o problema como não linear, utilizando o modelo de *ML* treinado ($f(\mathbf{X})$) como a função de produção. O foco reside em maximizar a Vazão Diária de Petróleo ($\hat{y}$) por meio do ajuste das variáveis operacionais controláveis ($\mathbf{X}$). A formulação matemática para este problema de otimização é apresentada a seguir:

$$\max_{\mathbf{X}} \quad \hat{y} = f(\mathbf{X}) \tag{2.5}$$

$$\text{s.t.} \quad L_{\min,j} \leq x_j \leq L_{\max,j}, \quad \forall j \in \{1,2,\ldots,p\} \tag{2.6}$$

$$x_{\text{Grau_API}} = C_{\text{API}} \tag{2.7}$$

$$x_{\text{Idade}} = C_{\text{Idade}} \tag{2.8}$$

$$\frac{x_{\text{Água}}}{x_{\text{Petróleo}}} \leq C_{\text{BSW_max}} \tag{2.9}$$

$$x_j \in \mathbb{R}_+, \quad \forall j \in \{1,2,\ldots,p\} \tag{2.10}$$

No modelo em questão, a equação (2.5) define a função objetivo, que estabelece a meta de maximizar a produção estimada $\hat{y}$. A função $f(\mathbf{X})$ consiste na relação preditiva complexa aprendida por algoritmos de *ML*, como *Random Forest* ou *Multilayer Perceptron* (MLP), capaz de capturar interações não lineares entre as variáveis.

As variáveis de decisão deste modelo são representadas pelo vetor $\mathbf{X} = \{x_1, x_2, \ldots, x_p\}$, composto pelos parâmetros operacionais que podem ser manipulados para influenciar a vazão. O domínio definido para essas variáveis na equação (2.10) como reais não negativos ($\mathbb{R}_+$) reflete a natureza física de grandezas como vazões e intervalos temporais.

A equação (2.6) determina o intervalo das variáveis controláveis $x_j \in \mathbf{X}$. Tais variáveis devem respeitar os limites mínimos ($L_{\min}$) e máximos ($L_{\max}$) de segurança e capacidade dos equipamentos.

Por fim, as equações (2.7)-(2.9) introduzem as constantes de projeto e qualidade C_k (onde $k \in \{\text{API, Idade, BSW_max}\}$). Estes parâmetros representam:

- **Valores Fixos ($C_{\mathbf{API}}, C_{\mathbf{Idade}}$):** Constantes que restringem o modelo a características específicas do poço em um dado instante, impossibilitando que o otimizador altere propriedades físicas imutáveis no curto prazo.
- **Limites Críticos ($C_{\mathbf{BSW_max}}$):** Valores de fronteira que definem o patamar máximo tolerável para o *Basic Sediment and Water*/Sedimentos Básicos e Água (BSW). O BSW é uma métrica crucial que quantifica o percentual de água e sedimentos presentes no fluido extraído. Um valor elevado indica o avanço da frente de água no reservatório, o que aumenta os custos operacionais de separação e tratamento, além de elevar os riscos de corrosão e incrustação na infraestrutura produtiva.

2.3 Métricas

Por fim, há também a necessidade de se otimizar as métricas de cada um dos modelos, visto que esses determinarão o quanto o modelo se adequa ao problema, e o quanto ele consegue predizer os valores da variável objetivo. Sendo assim, abaixo serão apresentadas as métricas utilizadas e que foram otimizadas:

- **Coeficiente de Determinação ($\mathbf{R^2}$):** O R^2 mede a proporção da variância total na variável alvo que é explicada pelo modelo. É a métrica primária de precisão.

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} = 1 - \frac{\text{RSS}}{\text{TSS}} \tag{2.11}$$

  Onde RSS é a Soma dos Quadrados dos Resíduos (erro do modelo) e *Total Sum of Squares* (TSS) é a variância total dos dados. Um R^2 próximo de 1 indica um ajuste excelente.
- **Raiz do Erro Quadrático Médio (RMSE):** O *Root Mean Squared Error*/Raiz do Erro Quadrático Médio (RMSE) é a principal métrica de erro, representando a magnitude média dos desvios. É a raiz quadrada da média dos erros quadrados, mantendo a unidade de medida original (bbl/dia) para interpretação prática.

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{2.12}$$

A função quadrática dentro da raiz penaliza erros grandes de forma desproporcional, tornando o RMSE sensível a *outliers*.

- **Erro Absoluto Médio (MAE):** O *Mean Absolute Error*/Erro Absoluto Médio (MAE) mede a média dos erros em valor absoluto.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{2.13}$$

Por não elevar o erro ao quadrado, o MAE é mais robusto contra *outliers* do que o RMSE e fornece uma estimativa de erro mais intuitiva.

- **Diferença do Coeficiente de Determinação (ΔR^2):** Esta métrica avalia a capacidade de **generalização** do modelo, sendo essencial para identificar o *overfitting*.

$$\Delta R^2 = R^2_{\text{Treino}} - R^2_{\text{Teste}} \tag{2.14}$$

Um ΔR^2 próximo de zero indica que o desempenho do modelo no conjunto de teste é similar ao do treino (boa generalização). Um valor positivo alto é um forte indicador de que o modelo memorizou os dados de treino, perdendo poder preditivo em dados não vistos.

3 FUNDAMENTAÇÃO TEÓRICA

Esta seção estabelece o arcabouço teórico e o estado da arte necessários para a compreensão e desenvolvimento da presente pesquisa, abrangendo a aplicação de conceitos de PO e de modelos de *ML* como ferramentas de otimização.

3.1 Fundamentos de PO

A PO é uma área do conhecimento aplicada a problemas envolvendo como conduzir e coordenar as chamadas operações (atividades ~~ou ativadades~~) em um determinado processo, sendo largamente utilizada nas mais distintas áreas, com suas origens sendo atribuídas aos primórdios da Segunda Guerra Mundial. (HILLIER; LIEBERMAN, 2013).

O estudo de um determinado problema, utilizando técnicas de PO envolve as seguintes fases (HILLIER; LIEBERMAN, 2013):

1. Definir o problema de interesse
2. Coletar dados.
3. Formular um modelo matemático para representar o problema.
4. Desenvolver um procedimento computacional a fim de derivar soluções para o problema a partir do modelo.
5. Testar o modelo e aprimorá-lo conforme necessário.
6. Preparar-se para a aplicação contínua do modelo conforme prescrito pela gerência.
7. Implementar computacionamente.

De acordo com (HILLIER; LIEBERMAN, 2013), para a formulação matemática do problema é necessário definir os seguintes componentes, com essas sendo essenciais para traduzir a questão gerencial em um problema de otimização solucionável:

- **Variáveis de Decisão:** Representam as escolhas que podem ser manipuladas pelo modelo para buscar o resultado ótimo.
- **Parâmetros:** Valores fixos no problema.
- **Restrições:** Limites físicos, regulatórios ou de recursos do problema que definem a região de soluções viáveis.
- **Função Objetivo:** O critério de desempenho a ser maximizado ou minimizado, a depender do problema em questão.

Cada problema pode ser classificado de diferentes formas com base em diferentes

aspectos, tais classificações serão abordadas nas seguintes subsseções.

3.2 Fundamentos de Limpeza de Dados para Modelagem

A precisão dos modelos de *ML* é fundamentalmente dependente da qualidade dos dados de treinamento. A literatura demonstra que a coleta massiva de dados, especialmente em grandes volumes, resulta em datasets "sujos"que podem comprometer a acurácia dos resultados de predição (RIDZUAN; Wan Zainon, 2019). A limpeza de dados é essencial para garantir que a informação esteja precisa e uniforme, resolvendo problemas como incompletude, inconsistência e duplicação (RIDZUAN; Wan Zainon, 2019).

A ausência de tratamento para valores faltantes ou erros pode gerar incertezas no dataset e produzir resultados distintos e, potencialmente, equivocados para a tomada de decisão. O processo de limpeza de dados é uma etapa complexa e crucial, que tipicamente envolve as seguintes cinco fases (RIDZUAN; Wan Zainon, 2019):

1. **Data Analysis (*Análise de Dados*):** É a fase de auditoria, na qual o objetivo é identificar e obter metadados sobre todas as anomalias, erros e inconsistências presentes no banco de dados.
2. **Definition of transformation workflow (*Definição do Fluxo de Trabalho de Transformação*):** Nesta etapa, é definida a sequência de operações e regras de mapeamento necessárias para a detecção e correção das anomalias identificadas na fase anterior.
3. **Verification (*Verificação*):** Consiste na avaliação da correção e da eficácia do fluxo de trabalho de transformação, frequentemente exigindo a interação com especialistas do domínio para validar as transformações aplicadas.
4. **Transformation (*Transformação*):** É a execução dos passos de correção. Os dados são transformados e atualizados utilizando as regras definidas no fluxo de trabalho.
5. **Backflow of cleaned data (*Retorno dos Dados Limpos*):** Fase final onde os dados sujos originais são substituídos pelos dados limpos e validados, garantindo que o dataset de entrada para a modelagem seja de alta qualidade.

No contexto deste trabalho, a garantia da alta qualidade dos dados utilizados foi um pré-requisito crucial para o treinamento robusto dos modelos *surrogate* propostos. O processo de limpeza e preparação do *dataset* incluiu os seguintes passos:

- **Estrutura e Consistência:** Padronização e renomeação de colunas (ex: 'Grau API' para 'Grau_API') e remoção de colunas redundantes ou com baixa variância (como 'Nome

Poço ANP' e outras colunas de vazão não essenciais).

- **Limpeza de Dados:** Remoção de registros duplicados para garantir a integridade.
- **Tratamento de *Outliers*:** Utilização do algoritmo *IsolationForest* para identificar *outliers*, sendo um algoritmo baseado em árvores, que faz o isolamento dos valores discripantes através de particionamentos aleatórios, levando em conta que tais valores exigem menos divisões para serem separados dos demais valores (LIU *et al.*, 2008).
- **Engenharia de *Features*:** Incorporação de atributos espaciais e operacionais provenientes de bases cadastrais complementares, com o objetivo de enriquecer a representação física dos poços e a capacidade preditiva dos modelos.

3.3 Fundamentos de *ML*

ML é um subcampo da Inteligência Artificial (IA) cujo objetivo principal é o desenvolvimento de técnicas computacionais que permitam a construção de sistemas capazes de adquirir conhecimento de forma automática, de forma que um sistema de aprendizado é essencialmente um programa de computador que toma decisões baseado em experiências acumuladas através da solução de problemas anteriores (MONARD; BARANAUSKAS, 2003).

Existem diferentes paradigmas de aprendizado, sendo o **Aprendizado Supervisionado** o mais utilizado em tarefas de regressão, como as aplicadas neste trabalho para a otimização da produção de poços de petróleo. Neste paradigma, o sistema recebe um conjunto de exemplos de treino, onde cada exemplo consiste num par entrada-saída desejada, permitindo que o algoritmo aprenda a mapear novas entradas com base no padrão identificado (MONARD; BARANAUSKAS, 2003).

A versatilidade desses paradigmas permitiu que o *ML* se consolidasse como uma ferramenta científica transversal, sendo aplicada com sucesso em domínios que variam desde a genômica e microbiologia até a engenharia de reservatórios (ASNICAR *et al.*, 2024). No entanto, a eficácia desses modelos em cenários complexos não são provenientes apenas da escolha do algoritmo, mas da implementação de um fluxo de trabalho rigoroso que prioriza a qualidade dos dados e a validação estatística. Essa perspectiva interdisciplinar reforça que, para que um modelo atue como um emulador confiável de fenômenos físicos — como a vazão de poços de petróleo —, é imprescindível a adoção de protocolos estritos de pré-processamento e limpeza de dados, visando garantir a generalização e evitar o *overfitting* (ASNICAR *et al.*, 2024).

3.3.1 Generalização e Overfitting

Um dos maiores desafios no treinamento de modelos de *ML* é garantir a sua capacidade de generalização, ou seja, a habilidade do sistema em realizar predições corretas para dados novos que não foram utilizados durante a etapa de treinamento (MONARD; BARANAUSKAS, 2003). Quando um modelo falha nesse aspecto, ocorre frequentemente o fenômeno do *overfitting* (sobreajuste).

O *overfitting* acontece quando o algoritmo "decora"as características específicas e os ruídos do conjunto de treinamento, apresentando um desempenho excelente nesta etapa, mas falhando ao ser avaliado em dados desconhecidos (ASNICAR *et al.*, 2024). Segundo Asnicar *et al.* (2024), um modelo sobreajustado pode ser enganoso, apresentando métricas de validação interna satisfatórias que não se sustentam na prática, o que compromete a sua utilidade em casos reais.

Para mitigar esse risco e assegurar que o modelo identifique apenas os padrões subjacentes reais, é fundamental adotar práticas rigorosas de validação e pré-processamento. Neste estudo, a aplicação do método de Intervalo Interquartil (IQR) para a remoção de *outliers* e o uso de técnicas de amostragem aleatória (detalhadas no Capítulo 4) foram estratégias essenciais para reduzir o ruído nos dados e, consequentemente, prevenir o *overfitting*, garantindo a robustez do modelo *surrogate* para a otimização de poços.

3.4 Modelos *Surrogate* na Otimização de Sistemas de Produção

Modelos *surrogate* — também referidos na literatura como modelos de resposta aproximada, metamodelos ou emuladores — são aproximações matemáticas de modelos de simulação numericamente intensivos (ASHER *et al.*, 2015). A premissa fundamental desta abordagem é a substituição de um simulador de alta fidelidade, que exige alto custo computacional e tempo de execução elevado, por um modelo estatístico ou computacional mais simples que seja capaz de mimetizar o comportamento do código original com precisão aceitável, mas a uma fração do custo original (ASHER *et al.*, 2015; ŠTUREK; LAZAROVA-MOLNAR, 2025).

De acordo com a taxonomia proposta por Asher *et al.* (2015), os modelos *surrogate* podem ser classificados em três categorias principais:

- **Modelos de Fidelidade Reduzida (*Lower-fidelity*):** Versões simplificadas do modelo físico, utilizando malhas mais grossas ou simplificações das equações governantes.

- **Modelos de Resposta de Baixa Ordem (*Reduced-order*):** Modelos que reduzem a dimensionalidade do sistema original preservando sua dinâmica essencial.
- **Modelos Baseados em Dados (*Data-driven*):** Também conhecidos como "caixa-preta", estes modelos utilizam técnicas de Aprendizado de Máquina para mapear a relação entre as entradas e saídas do simulador original, sem o conhecimento explícito da física interna do sistema.

Este trabalho foca na terceira categoria, utilizando *ML* para construir emuladores baseados em dados. Como destacado por Šturek e Lazarova-Molnar (2025), esses modelos são essenciais para viabilizar simulações em tempo real e ciclos de otimização iterativos em ambientes de Indústria 4.0, onde a agilidade na tomada de decisão é um requisito crítico.

3.5 Formalização Matemática dos Modelos de Aprendizado de Máquina

Conforme discutido na Seção 3.4, os modelos baseados em dados utilizam algoritmos de Aprendizado de Máquina para mapear as relações entre as variáveis de entrada e saída. Nesta seção, apresenta-se a fundamentação matemática dos modelos empregados para a construção do *surrogate*, abrangendo desde regressões lineares até arquiteturas complexas de redes neurais e *ensembles*.

No paradigma de aprendizado supervisionado, o objetivo é encontrar uma função de mapeamento f tal que $y = f(\mathbf{x}) + \varepsilon$, minimizando uma **Função de Perda**, como o *Mean Squared Error*/Erro Quadrático Médio (MSE), para garantir a capacidade de generalização e evitar o *overfitting* (ASNICAR *et al.*, 2024; MONARD; BARANAUSKAS, 2003).

3.5.1 Regressores Lineares e Regularização

Os modelos lineares fundamentam-se na premissa de que a variável de saída pode ser expressa como uma combinação linear das variáveis de entrada: $\hat{y} = w_0 + \sum_{i=1}^{n} w_i x_i$ (JAMES *et al.*, 2013). Para mitigar o risco de *overfitting* e controlar a magnitude dos coeficientes, aplicam-se técnicas de regularização que penalizam a complexidade do modelo:

- **LinearRegression:** Implementa o método de *Ordinary Least Squares*/Mínimos Quadrados Ordinários (OLS), buscando minimizar a soma dos resíduos quadrados sem a aplicação de penalidades adicionais (JAMES *et al.*, 2013).
- **Lasso (L_1) e Ridge (L_2):** O modelo *Ridge* introduz uma penalidade proporcional ao

quadrado dos pesos ($\lambda||w||_2^2$), enquanto o *Lasso* utiliza a norma L_1 ($\lambda||w||_1$) (JAMES *et al.*, 2013). A característica distintiva do *Lasso* é sua capacidade de realizar a seleção de variáveis, reduzindo a zero os coeficientes de preditores menos relevantes.

3.5.2 Modelos de Vizinhança e Suporte (KNN e SVR)

- ***K-Nearest Neighbors* (KNN):** É um método não-paramétrico que baseia suas predições na similaridade local. A saída para uma nova instância é calculada como a média das saídas observadas nos k vizinhos mais próximos dentro do espaço euclidiano de características (MONARD; BARANAUSKAS, 2003; JAMES *et al.*, 2013).
- ***Suport Vector Regression* (SVR):** Originário da teoria de suporte estatístico, o SVR busca encontrar um hiperplano de regressão que mantenha a maior parte dos dados dentro de uma margem de tolerância ε. O uso de funções de *kernel* permite que o modelo mapeie as entradas em espaços de alta dimensão, capturando relações não-lineares complexas (HASTIE *et al.*, 2009; MONARD; BARANAUSKAS, 2003).

3.5.3 Modelos Baseados em Árvores e Ensembles (Random Forest e XGBoost)

Os métodos de conjunto (*ensembles*) combinam múltiplas árvores de decisão para produzir um modelo preditivo mais robusto.

- **Random Forest:** Baseia-se no princípio de *Bagging* (*Bootstrap Aggregating*), onde diversas árvores são treinadas de forma independente em subamostras dos dados. A predição final resulta da média dessas subestimativas, o que reduz drasticamente a variância sem aumentar o viés (BREIMAN, 2001; JAMES *et al.*, 2013).
- **XGBoost:** Representa uma implementação otimizada de *Gradient Boosting*. Diferente do *Bagging*, as árvores são construídas sequencialmente para minimizar os erros residuais das árvores predecessoras por meio do gradiente da função de perda, incorporando termos de regularização para assegurar a generalização do modelo (CHEN; GUESTRIN, 2016).

3.5.4 Redes Neurais Artificiais (MLP)

As Redes Neurais do tipo MLP são compostas por camadas de neurônios altamente interconectados. A saída de cada unidade é processada por $\hat{y} = \sigma(\mathbf{w}^T\mathbf{x} + b)$, onde σ representa uma função de ativação não-linear (como ReLU ou Sigmoide), essencial para a aproximação de

funções complexas (GOODFELLOW *et al.*, 2016). O processo de aprendizado fundamenta-se no algoritmo de *backpropagation*, que utiliza o gradiente descendente para ajustar os pesos e vieses da rede, minimizando o erro de predição em relação aos dados do simulador original (MONARD; BARANAUSKAS, 2003; GOODFELLOW *et al.*, 2016).

4 PROPOSTA E METODOLOGIA

Neste capítulo, apresentam-se a proposta central e os procedimentos metodológicos adotados para a execução dos experimentos computacionais deste trabalho. Ressalta-se que todos os procedimentos e rotinas de cálculo foram desenvolvidos utilizando a linguagem Python.

A proposta deste trabalho consiste no desenvolvimento e na validação de um ecossistema de modelos de *ML* capaz de emular o comportamento de simuladores físicos de poços de petróleo, permitindo a predição de vazões e a otimização de cenários operacionais. Para a viabilização desta proposta, definem-se as seguintes frentes de atuação:

- Analisar o comportamento dos dados e a relação entre as variáveis físicas por meio de matrizes de correlação, identificando o grau de dependência entre elas e evitando possíveis enviesamentos no modelo.
- Avaliar a natureza do problema (linear ou não linear) com base no desempenho das métricas obtidas, utilizando esses resultados para orientar a escolha das arquiteturas de *ML* mais eficazes.
- Treinar e comparar diferentes algoritmos de *ML*, selecionando aquele que apresente a melhor precisão e capacidade de generalizar para novos cenários de produção.
- Consolidar os resultados em um trabalho técnico que contribua para a literatura da área e sirva de base sólida para a dissertação de mestrado.

Endereço?

No que tange à metodologia, a etapa inicial consistiu na extração de dados de produção de poços de petróleo *offshore* situados em diversas bacias brasileiras. Esses dados foram obtidos por meio do sistema de CDP da Petrobras, que organiza e disponibiliza os registros com periodicidade mensal. Para compor a base deste estudo, foram selecionados os arquivos referentes ao intervalo entre janeiro de 2018 e dezembro de 2025.

Devido à padronização de colunas e formatos mantida pela plataforma, os arquivos mensais foram importados e consolidados em um único *dataframe* utilizando a biblioteca Pandas da linguagem Python. A escolha desta biblioteca justifica-se pela sua eficiência na manipulação de grandes volumes de dados estruturados e pelo suporte a operações complexas de limpeza e tratamento, fundamentando-se nos conceitos discutidos na Seção 3.2. Com as funcionalidades dessa biblioteca, foi utilizado um *script* que foi responsável pela remoção de atributos considerados desnecessários para a modelagem, categorizados da seguinte forma:

- **Dados Administrativos e Geográficos:** Variáveis como "Estado", "Bacia", "Operador", "Nome Poço Operador", "Número do Contrato"e informações sobre instalações ("Insta-

lação Destino", "Tipo Instalação") foram removidas. Esses atributos funcionam apenas como identificadores ou metadados geográficos, não possuindo correlação física direta com as dinâmicas de produção que o modelo *surrogate* visa emular.

- **Metadados de Controle e Sistema:** Colunas como "Período da Carga", "Corrente"e "Data de atualização"foram descartadas por tratarem-se de registros temporais de auditoria interna da plataforma de CDP, sendo irrelevantes para o comportamento produtivo dos poços.
- **Composição Química de Alta Granularidade:** A análise detalhada da composição molar do gás (frações de metano, etano, propano até undecanos, além de gases inertes) e as frações de destilados foram excluídas. A manutenção desses atributos de alta granularidade aumentaria excessivamente a complexidade do modelo, podendo introduzir ruído e dificultar a generalização para diferentes cenários de reservatório.
- **Variáveis Redundantes ou de Escopo Secundário:** Métricas de vazão secundárias, como "Condensado (bbl/dia)"e a distinção entre "Gás Natural Assoc/N Assoc", foram removidas para evitar a colinearidade com as variáveis alvo principais, simplificando a arquitetura do modelo sem perda de fidelidade na representação do sistema.

Após a seleção de atributos, foi realizada a adequação dos tipos de dados das colunas remanescentes no *dataframe* do Pandas. Com exceção de três variáveis, uma contendo o nome do poço registrado pela Petrobras, uma com o nome do campo no qual o poço está instalado, e outra contendo o período em que os dados daquela linha foram registrados (mês e ano), as demais colunas foram convertidas para o formato numérico, garantindo a compatibilidade com os algoritmos de aprendizado de máquina.

Uma etapa crítica nesta fase foi a conversão do separador decimal. Visto que os dados brutos seguiam o padrão regional brasileiro (uso de vírgula), foi implementada uma rotina de tratamento para a substituição sistemática da vírgula pelo ponto. Essa normalização sintática é essencial para que o interpretador Python reconheça os registros como valores de ponto flutuante (*float*), permitindo que o Pandas processe as colunas tanto como variáveis preditoras quanto como variáveis alvo.

Concluída a correção dos tipos, realizou-se o tratamento de dados ausentes por meio da exclusão de todas as instâncias que continham valores nulos (*NaN - Not a Number*). Esta ação visou mitigar o risco de erros durante a etapa de treinamento e assegurar a integridade estatística do conjunto de dados. Ressalta-se que a remoção das linhas nulas foi executada propositalmente

após a conversão tipológica; no Pandas, objetos nulos em colunas numéricas são tratados como ponto flutuante, o que permitiu que o tratamento de valores faltantes fosse realizado de forma consistente com a estrutura final do *dataframe*.

Para complementar a preparação do *dataframe* e enriquecer o conjunto de variáveis preditoras, realizou-se uma etapa de engenharia de atributos (*feature engineering*). Esta fase envolveu a integração do *dataset* principal com dois novos conjuntos de dados, um disponibilizado pelo CDP contendo informações cadastrais dos poços, e outro disponibilizado pelo site do Gov.

No primeiro conjunto de dados foi possível realizar o cruzamento entre as bases, utilizando o nome do poço como chave de ligação, extraindo as datas de início de operação de cada unidade e sincronizando com as datas dos registros mensais de produção. Dessa forma, foi possível calcular o delta temporal de atividade de cada poço. Essa nova variável, denominada "Idade", armazena o número total de dias decorridos desde o início da operação até o momento do registro, fornecendo ao modelo uma métrica contínua do tempo de vida e do estágio de maturação do poço. Além disso, foi possível obter a informação da "lâmina d'água"de cada um dos poços, com essa nova variável representando a distância exata entre a superfície da água e o fundo do mar, sendo uma informação que pode vir a contribuir com a qualidade de predição dos modelos.

Já no segundo conjunto de dados, foi possível obter dados acerca do preço de referência do petróleo em cada um dos meses analisados, sendo feita a segmentação dos preços com base no nome do Campo em que está sendo extraído o petróleo, e essa última informação também foi utilizada para realizar o cruzamento dos dados.

Com isso, as colunas utilizadas para os cruzamentos — nome do poço, nome do campo e períodos temporais específicos — foram removidas do *dataframe*, evitando assim a redundância e reduzindo a dimensionalidade dos dados para o treinamento dos algoritmos.

Após a consolidação das variáveis de entrada, foram selecionados exclusivamente os registros de poços situados na Bacia de Campos, no estado do Rio de Janeiro. Essa filtragem espacial foi adotada para garantir que os modelos aprendam sobre um conjunto de poços com características físicas e operacionais próximas, evitando o treinamento com dados provenientes de contextos geológicos muito divergentes. Adicionalmente, a escolha dessa região justifica-se por representar o maior volume de observações disponíveis no *dataframe*.

Por fim, para obter o *dataframe* final utilizado pelos modelos, realizou-se o tratamento de anomalias e redundâncias, fase crítica para assegurar a veracidade e a integridade

dos dados antes do treinamento. Inicialmente, foram removidos todos os registros duplicados, garantindo que instâncias repetidas não gerassem um enviesamento indevido nos algoritmos. Na sequência, foram removidos registros com preenchimento inconsistente, considerando que registros com as variáveis de Vazão de Petróleo, Vazão de Água, Vazão de Gás e Lámina D'Água iguais a zero representam inconsistências. Para fazer a detecção dos *outliers* foi utilizada a biblioteca *IsolationForest* do Python, utilizando os valores númericos do *dataframe* para treinar o modelo, para que esse possa fazer a detecção dos valores discrepantes.

A exclusão, tanto de valores inconsistentes, quanto dos *outliers* visou assegurar que o treinamento ocorresse sobre um conjunto de dados representativo do comportamento operacional típico, melhorando assim a precisão e a confiabilidade das predições. Com a conclusão deste fluxo, o conjunto de dados apresentou-se devidamente limpo e enriquecido para a execução dos experimentos computacionais.

Para a execução dos experimentos, o *dataframe* foi segmentado em duas componentes fundamentais: o conjunto de atributos (*features* ou *inputs*) e a variável alvo (*target* ou *output*). Enquanto a variável alvo representa a grandeza que o modelo deve estimar, as *features* constituem o vetor de variáveis independentes que fornecem os subsídios necessários para que o algoritmo identifique padrões de produção e realize as predições desejadas.

A partir dessa segmentação, utilizou-se o método `train_test_split` da biblioteca Scikit-learn para a partição dos dados em conjuntos de **treino** e **teste**. O conjunto de treino foi destinado ao ajuste dos parâmetros internos dos modelos, ao passo que o conjunto de teste foi reservado exclusivamente para avaliar a capacidade de generalização e o desempenho preditivo das arquiteturas propostas. A divisão foi realizada de forma aleatória na proporção de 80% para treinamento e 20% para teste, garantindo a mútua exclusão entre as amostras para evitar o sobreajuste (*overfitting*).

Com os dados devidamente particionados, procedeu-se à normalização das *features* utilizando a classe `StandardScaler`. Este procedimento realiza o escalonamento dos atributos para que possuam média zero e variância unitária, o que é fundamental para algoritmos sensíveis à escala das variáveis, como MLP, KNN e SVR. É importante ressaltar que o ajuste do escalonador (*fit*) foi realizado apenas sobre os dados de treino, sendo posteriormente aplicado (*transform*) aos dados de teste. Essa estratégia é adotada para evitar o *data leakage* (vazamento de dados), garantindo que informações estatísticas do conjunto de teste não influenciem o processo de treinamento, simulando assim um cenário real de aplicação onde dados futuros são desconhecidos

pelo modelo.

Após a normalização dos dados, foi possível realizar a etapa de treinamento e avaliação dos modelos de *ML*. Os experimentos foram conduzidos seguindo uma progressão de complexidade, iniciando-se pelos modelos lineares para o estabelecimento de uma linha de base de desempenho.

Inicialmente, foram executados os algoritmos de **Linear Regression**, seguido das técnicas de regularização **Ridge** e **Lasso**. Estes modelos permitiram verificar se a relação entre as variáveis de entrada e a vazão de produção apresentava um comportamento predominantemente linear. Na sequência, explorou-se a capacidade de modelos baseados em conjuntos (*ensembles*), utilizando o **Random Forest** e o **XGBoost** (*Gradient Boosting*), visando capturar interações não lineares e aumentar a robustez das predições frente a possíveis ruídos nos dados.

Dando continuidade aos testes, foram implementados os modelos de **KNN** e **SVR**, que utilizam métricas de distância e funções de *kernel* para mapear o espaço de atributos. Por fim, utilizou-se a rede neural **MLP**, visando explorar a capacidade de aproximação de funções altamente complexas e não lineares. Para cada um dos modelos citados, foram extraídas métricas estatísticas de erro no conjunto de teste, permitindo uma análise comparativa rigorosa da eficácia de cada arquitetura na emulação do comportamento dos poços.

Para cada modelo, exceto o de Regressão Linear, foi utilizada a classe `GridSearchCV`, que realiza uma busca exaustiva sobre um espaço de parâmetros previamente especificado. Este método opera em conjunto com a técnica de validação cruzada (*k-fold cross-validation*), dividindo o conjunto de treinamento em subpartes para garantir que a escolha dos melhores hiperparâmetros seja estatisticamente robusta e não dependente de uma única partição dos dados.

A aplicação desta técnica foi fundamental para ajustar parâmetros críticos, como o coeficiente de penalidade (α) nos modelos Lasso e Ridge, a profundidade máxima das árvores no Random Forest e XGBoost, e a estrutura de neurônios ocultos na MLP. Inicialmente, o `GridSearchCV` foi configurado para selecionar a combinação que maximizasse o coeficiente de determinação (R^2) no conjunto de validação, porém, após alguns testes, a ferramenta foi configurada para minimizar o RMSE, de modo a reduzir a magnitude dos erros. Essa mudança na estratégia do `GridSearch` foi feita sobre a justificativa de buscar melhorias de novas métricas, visto que o R^2 já estava atingindo valores satisfatórios. Tal abordagem assegura que a comparação final entre os modelos seja justa, uma vez que todos os algoritmos foram avaliados em suas configurações otimizadas.

Com todas as métricas estatísticas extraídas dos modelos, bem como o tempo de execução de todas as suas combinações utilizadas no `GridSearchCV`, tais informações foram registradas a fim de comparar e tirar conclusões sobre os algoritmos, de modo a tomar as melhores decisões levando em consideração o problema abordado no seguinte trabalho. As conclusões serão apresentadas no Capítulo 5.

Após a conclusão dos experimentos, todas as métricas estatísticas de desempenho, juntamente com o custo computacional — mensurado pelo tempo de execução das combinações exaustivas do `GridSearchCV` — foram consolidadas para análise. Esse conjunto de dados foi fundamental para fundamentar uma análise comparativa rigorosa entre os algoritmos, permitindo avaliar o equilíbrio entre precisão preditiva e eficiência computacional. Dessa forma, a seleção do modelo ideal foi pautada por critérios técnicos alinhados às necessidades de emulação de sistemas de produção de poços marítimos. As análises detalhadas e as discussões sobre o desempenho de cada arquitetura serão apresentadas no Capítulo 5.

5 EXPERIMENTOS COMPUTACIONAIS

Este capítulo apresenta a consolidação e a discussão aprofundada dos resultados obtidos através da otimização e avaliação de diversas famílias de algoritmos de Machine Learning. O objetivo primário foi identificar o modelo com o melhor balanço entre **precisão preditiva** (maior R^2 de Teste e menor RMSE de Teste) e **capacidade de generalização** (ΔR^2 minimizado) para a previsão da Vazão Diária de Petróleo.

Todos os modelos foram treinados sobre o *dataframe*, que foi gerado a partir da união de diferentes *dataframes*, disponibilizados pela Petrobras no Sistema de CDP, cada um desses *dataframes* possuia informações de diferentes poços com base no mês e no ano, sendo utilizados dados de janeiro de 2018 até dezembro de 2025. Com o *dataframe* final gerado, foi realizado o tratamento de *outliers* e a aplicação das técnicas de *Feature Engineering* para melhor preparar os dados para os modelos. O *baseline* de comparação é a média de produção do *dataframe* final de **2481.8066** bbl/dia, a partir da qual o RMSE é percentualmente avaliado.

5.1 Métricas Consolidadas de Desempenho

A Tabela 1 resume as métricas de desempenho de precisão (R^2 e RMSE), generalização (ΔR^2) e eficiência computacional (*Tempo de Treinamento em segundos*) para os oito modelos otimizados.

Tabela 1 – Métricas Consolidadas de Desempenho dos Modelos

Modelo	R^2 Treino	R^2 **Teste**	RMSE Teste	MAE Teste	ΔR^2	RMSE Teste / Média	MAE Teste / Média	Tempo (segundos)
Regressão Linear	0.6132	0.4298	1445.9133	836.3803	0.1834	58.26%	33.70%	0.0041
Ridge	0.6132	0.43	1445.6981	836.0452	0.1832	58.25%	33.69%	0.0044
Lasso	0.613	0.4323	1442.7142	831.2112	0.1807	58.13%	33.49%	2.4176
Random Forest	0.9902	0.7959	865.0745	595.476	0.1943	34.86%	23.99%	21.6028
XGBoost	0.9977	0.8325	783.7745	554.3656	0.1652	31.58%	22.34%	4.742
K-NN	1.0000	0.7334	988.6921	672.0284	0.2666	39.84%	27.08%	0.0151
SVR	0.8882	0.7925	872.3204	602.3066	0.0857	35.15%	24.27%	2.82
MLP	0.9974	0.7494	958.6022	689.2463	0.258	38.63%	27.77%	232.1247

5.2 Análise e Discussão dos Resultados

A análise dos resultados se divide em três pontos principais: a performance dos modelos lineares, o salto de precisão dos modelos não-lineares, e a comparação de *trade-offs*

entre os modelos de maior performance.

5.2.1 Performance dos Modelos Lineares (Base)

Os modelos de Regressão Linear, Ridge e Lasso apresentaram um R^2 de Teste de aproximadamente **0.57**. Este resultado indica que a abordagem linear consegue explicar apenas 57% da variabilidade da vazão de petróleo. O erro associado é extremamente alto, com um RMSE na casa de **789** bbl/dia, o que representa **87**% da produção média. Apesar da baixa precisão, estes modelos demonstram excelente generalização, com ΔR^2 muito próximos de zero, confirmando que a relação entre as variáveis de engenharia de poços é inerentemente não-linear, sendo subestimada pela simplicidade dos modelos lineares (alto *bias*).

5.2.2 O Salto de Precisão dos Modelos Não-Lineares

A migração para algoritmos capazes de mapear relações não-lineares resultou em um aumento substancial e imediato no poder preditivo:

- O R^2 de Teste subiu de 0.57 para mais de **0.92** nos melhores modelos.
- O erro (RMSE) foi drasticamente reduzido de 789 bbl/dia para aproximadamente **325** bbl/dia, o que representa uma redução de mais de **58**% no erro preditivo.

O **Random Forest** e o **MLP Regressor** se destacaram, alcançando os melhores resultados de R^2 de Teste (0.9272 e 0.9268, respectivamente).

5.2.3 Análise do Trade-Off: Precisão, Generalização e Tempo

A escolha do modelo final é determinada pelo balanceamento entre precisão, generalização e eficiência computacional.

- **Generalização (ΔR^2):** O **SVR** apresentou a melhor generalização absoluta ($\Delta R^2 = 0.0092$), mas sua precisão final ($R^2 = 0.8947$) foi inferior. Entre os modelos de alta performance ($R^2 > 0.92$), o **Random Forest** apresentou a menor perda de generalização ($\Delta R^2 = 0.0620$), indicando que sua estrutura é mais robusta e menos suscetível ao *overfitting* do que o MLP e o XGBoost.
- **Eficiência (Tempo de Treinamento):** A diferença de tempo é crítica:
  - O **XGBoost** se mostrou o mais eficiente, treinando em menos de **1** segundo (**0.78 segundo**). Para cenários de produção com necessidade de re-treinamento rápido, o

XGBoost é preferível.

- O **Random Forest** exigiu 27.63 segundos, o que é aceitável.
- O **MLP Regressor** foi o mais lento (158.33 segundos), sendo a escolha mais custosa computacionalmente.

5.3 Definição do Modelo Final

Com base na análise das métricas, o **Random Forest Regressor** é definido como o modelo final e recomendado para o projeto.

- Ele atingiu o $\mathbf{R^2}$ de Teste mais alto ($\mathbf{0.9272}$), garantindo o maior poder explicativo.
- Seu RMSE de $\mathbf{325.48}$ bbl/dia representa o menor erro médio de previsão.
- Conseguiu manter a melhor relação de generalização ($\Delta R^2 = 0.0620$) entre os modelos de ponta, demonstrando a melhor robustez na aplicação a novos dados.

A arquitetura de *bagging* (Random Forest) demonstrou ser mais estável e generalizável para este conjunto de dados complexo do que a arquitetura de *boosting* (XGBoost) e a Rede Neural (MLP).

Todos os experimentos foram realizados em um computador com as seguintes configurações:

- **Processador:** AMD Ryzen 5 5600GT com 3.60 GHz.
- **Memória:** 16 GB de RAM.
- **Placa de Vídeo:** NVIDIA GeForce RTX 3050 com 8 GB de VRAM.

6 CONCLUSÃO

O presente trabalho conseguiu cumprir seu objetivo de desenvolver um modelo de *ML* que se adeque aos dados de produção de poços de petróleo marítimo a fim de otimizar sua produção. O problema em questão, após análises comparativas das métricas dos modelos, demonstrou possuir uma natureza não linear, dado que modelos mais simples, que consideram o problema como linear, não conseguiram se adequar aos dados, explicando apenas cerca de 57% da variabilidade dos dados com um RMSE muito elevado, com valores que representam 87% da média de produção diária.

Dentre todos os modelos, o **Random Forest** fo aquele que se destacou por conseguir se adequar os dados, conseguindo predizer bem os valores de produção de petróleo diário, com uma taxa de acerto de 92%, e com a média dos valores dos erros estando em torno de 36% da média de produção diária dos poços. Além disso, o modelo apresentou um bom tempo para o treinamento, tendo uma média de 27 segundos para a realização dessa etapa.

7 CRONOGRAMA

A seguir, serão apresentadas as tarefas do plano de pesquisa do trabalho em questão:

Tarefa 1: Estudo da biblioteca de otimização matemática `gurobipy`, da linguagem Python, a fim de integrá-la ao modelos utilizados para alcançar possíveis melhorias nos resultados obtidos nesse trabalho.

Tarefa 2: Estudo e testes de modelos de *Deep Learning* e de *Physics-Informed Neural Network*/Rede Neural Informada pela Física (PINN), para observar se tais modelos conseguem se adaptar melhor ao problema e aos dados em questão.

Tarefa 3: Atualização dos códigos de treinamento, ajustando os hiperparâmetros dos modelos já utilizados, integrando os novos modelos estudados, bem como a biblioteca `gurobipy`. Tais modificações têm como objetivo a obtenção de resultados melhores aos apresentados nesse trabalho, desse modo, continuará sendo utilizada a técnica de validação cruzada (*cross-validation*) e um busca exaustiva para os novos testes.

Tarefa 4: Escrita do texto da dissertação.

Tarefa 5: Escrita de artigo sobre os resultados.

Tarefa 6: Defesa de dissertação.

Quadro 1 – Cronograma de execução do trabalho

Etapas	2026								
	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Tarefa 1	X								
Tarefa 2		X							
Tarefa 3			X	X	X				
Tarefa 4	X	X	X	X	X	X	X		
Tarefa 5					X	X	X	X	
Tarefa 6									X

REFERÊNCIAS

ASHER, M. J.; CROKE, B. F. W.; JAKEMAN, A. J.; PEETERS, L. J. M. A review of surrogate models and their application to groundwater modeling. **Water Resources Research**, v. 51, n. 8, p. 5957–5973, 2015.

ASNICAR, F.; THOMAS, A. M.; PASSERINI, A.; WALDRON, L.; SEGATA, N. Machine learning for microbiologists. **Nature Reviews Microbiology**, v. 22, n. 4, p. 191–205, Apr 2024.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016.

GAO, S.; LI, H.; NIE, S.; AI, Y.; LUO, H.; LI, Y. Design and numerical simulation study of a novel aicd for water control and gas production in gas wells. **ACS Omega**, American Chemical Society, v. 8, p. 39052–39066, 2023.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer Science & Business Media, 2009. Disponível em: <https://web.stanford.edu/~hastie/ElemStatLearn/>.

HILLIER, F. S.; LIEBERMAN, G. J. **Introdução à pesquisa operacional**. [S.l.]: McGraw Hill Brasil, 2013.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning: with Applications in R**. [S.l.]: Springer, 2013.

LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation forest. In: IEEE. **2008 eighth ieee international conference on data mining**. [S.l.], 2008. p. 413–422.

MARTINS, S. S. S.; SILVA, M. P.; AZEVEDO, M. O.; SILVA, V. P. Produção de Petróleo e Impactos Ambientais: Algumas Considerações. **HOLOS**, v. 6, n. 1807-1600, p. 54–76, 2015. ISSN 1807-1600.

MME, M. **Como uma plataforma tira petróleo do fundo do mar?** 2023. Disponível em: <https://www.gov.br/mme/pt-br/assuntos/noticias/como-uma-plataforma-tira-petroleo-do-fundo-do-mar>. Acesso em: 05 nov. 2025.

MONARD, M. C.; BARANAUSKAS, J. A. Conceitos sobre aprendizado de máquina. **Sistemas inteligentes - Fundamentos e aplicações**, v. 1, n. 1, p. 32, 2003.

MORAIS, J. M. d. Determinantes das Tecnologias de Produção de Petróleo no Mar. **Radar - Tecnologia, Produção e Comércio Exterior**, IPEA, n. 17, p. 27–34, 2011. Disponível em: <http://repositorio.ipea.gov.br/handle/11058/3460>.

RIDZUAN, F.; Wan Zainon, W. M. N. A review on data cleansing methods for big data. **Procedia Computer Science**, v. 161, p. 731–738, 2019. ISSN 1877-0509. The Fifth Information Systems International Conference, 23-24 July 2019, Surabaya, Indonesia.

SIKANYIKA, E. W.; WU, Z.; MBAROUK, M. S.; MAFIMBA, A. M.; ELBALOULA, H. A.; JIANG, S. Numerical simulation of the oil production performance of different well patterns with water injection. **Energies**, MDPI, v. 16, p. 91, 2023.

TSUKADA, R. I.; YAMAMOTO, M.; MOROOKA, C. K. Análise de Operação da Instalação de Risers e Descida de BOP em Sondas Flutuantes de Perfuração. In: **PDPETRO - Congresso Brasileiro de Pesquisa e Desenvolvimento em Petróleo e Gás**. Campinas, SP: [s.n.], 2007. p. 2.4.308–1–2.4.308–9.

WU, G.; MA, Y.; CAO, Y.; ZHANG, A.; LIU, W.; WANG, J.; YANG, X. Optimization of well patterns in offshore low-permeability thin interbedded reservoirs: A numerical simulation study in the bozhong oilfield, china. **Energies**, MDPI, v. 18, p. 285, 2025.

ŠTUREK, D.; LAZAROVA-MOLNAR, S. Surrogate modeling: Review and opportunities for expert knowledge integration. **Procedia Computer Science**, Elsevier B.V., v. 257, p. 826–833, 2025.